

UNIVERSITÀ DEGLI STUDI DI MILANO–BICOCCA
SCUOLA DI ECONOMIA E STATISTICA

CORSO DI LAUREA IN
SCIENZE STATISTICHE ED ECONOMICHE



DAL LANCIO AI PRIMI 20 GIORNI:
VALORE INFORMATIVO E REGOLE DI
INTERVENTO PER CAMPAGNE DI
BENEFICENZA

RELATORE: Dott. Marco Guerzoni

CORRELATORE: Dott. Riccardo Corradin

TESI DI LAUREA DI:

Daniel Wolff

MATRICOLA N. 861338

ANNO ACCADEMICO 2024/2025

Indice

0.1	Abstract	1
1	Struttura dei dati, flusso informativo e metodologia	3
1.1	Introduzione metodologica	3
1.2	Struttura del dataset	4
1.2.1	Variabili target	4
1.2.2	Problema di sbilanciamento	5
1.3	Variabili statiche	6
1.3.1	Variabili monetarie	6
1.4	Variabili testuali generate	7
1.5	Variabili dinamiche: early traction (1–20 giorni)	9
1.6	Data leakage	10
1.7	Scelta dei modelli	11
1.8	Validazione	11
1.9	Sintesi	11
2	Metodologia	13
2.1	Obiettivo operativo e formulazione del problema	13
2.2	Vincolo informativo e prevenzione del data leakage	13
2.2.1	Set informativo $\mathcal{I}_{i,d}$	14
2.3	Validazione out-of-sample e rischio di bias da selezione	14
2.4	Random Forest: teoria essenziale e setup sperimentale	15
2.4.1	Principio del metodo	15
2.4.2	Disegno dell’esperimento: EX-ANTE vs DAY-20	15
2.4.3	Sbilanciamento, metrica di tuning e scelta della soglia	15
2.4.4	Metriche riportate e intervalli di confidenza	15
2.4.5	Interpretabilità: importance e controllo di robustezza	16
2.5	BART day-by-day: modello, trasformazioni e output probabilistici	16
2.5.1	Modello di regressione	16

2.5.2	Trasformazione dell'outcome e scala interpretabile	17
2.5.3	Output bayesiano e intervalli predittivi	17
2.5.4	Diagnostiche dell'incertezza: coverage e width	17
2.6	Selezione non arbitraria dei giorni chiave (best, near-optimal, plateau)	18
2.7	Dalla regressione alla decisione: probabilità di soglia	18
2.8	Decision Curve Analysis: Net Benefit e robustezza	19
2.8.1	Bande al 90% via bootstrap bayesiano e soglie robuste	19
2.9	Decisione multistadio: Value of Information e stop-waiting	19
2.10	Sintesi della pipeline metodologica	20
3	Risultati Random Forest	21
3.1	Setup sperimentale e validazione	21
3.1.1	Obiettivo e scenari di confronto	21
3.1.2	Modello, tuning e gestione dello sbilanciamento	21
3.1.3	Metriche di valutazione e intervalli di confidenza	22
3.2	Confronto delle performance: EX-ANTE vs DAY-20	22
3.2.1	Risultati principali sul test set	22
3.2.2	Interpretazione del salto prestazionale	23
3.3	Ottimizzazione della soglia e MCC	24
3.3.1	Stima della soglia ottimale su predizioni OOF	24
3.3.2	DAY-20: forma della curva e robustezza del plateau	24
3.3.3	EX-ANTE: soglia più fragile e bassa separazione	25
3.4	Capacità discriminativa: curve ROC	25
3.4.1	DAY-20	25
3.4.2	EX-ANTE	26
3.5	Importanza delle variabili	27
3.5.1	Aggregazione per gruppi	27
3.5.2	Top feature	29
4	Risultati BART	35
4.1	Impostazione del problema e metriche	35
4.2	Accuratezza predittiva day-by-day e giorni chiave	36
4.2.1	Andamento dell'errore e identificazione dei giorni chiave	36
4.2.2	Guadagno informativo marginale e rendimenti decrescenti	37
4.3	Diagnostiche di previsione: struttura dell'errore e incertezza	38
4.3.1	Calibrazione dell'incertezza: coverage al 95%	38

4.3.2	Predetto vs vero nei giorni chiave: errori residui e saturazione	39
4.4	Sintesi numerica delle performance predittive	40
4.4.1	Metriche sui giorni chiave (near-optimal, plateau, best)	40
4.4.2	Top 10 giorni per RMSE_pct: “piattezza” della parte alta	41
4.5	Risultati decisionali: Decision Curve Analysis (DCA)	42
4.5.1	Dal modello continuo all’evento operativo e definizione del beneficio netto	42
4.5.2	Primo giorno decisionalmente utile	43
4.5.3	Curve decisionali nei giorni chiave: lettura qualitativa	43
4.5.4	Sintesi numerica DCA nei giorni chiave	46
4.6	Value of Information e regola di <i>stop-waiting</i>	49
4.6.1	VOI: formalizzare il valore dell’attesa	49
4.6.2	VOI per $T = 75\%$: utilità puntuale vs utilità robusta	49
4.6.3	VOI per $T = 100\%$: attesa raramente conveniente in senso robusto	50
4.6.4	Regola di <i>stop-waiting</i> e implicazione operativa	51
4.7	Lettura complessiva dei risultati	52
5	Discussione	53
5.1	Quadro unitario: due esperimenti, un messaggio comune	53
5.2	Random Forest: EX-ANTE vs DAY-20 come esperimento sul contenuto informativo	54
5.2.1	Perché EX-ANTE risulta debolmente predittivo	54
5.2.2	DAY-20: un salto strutturale, non un miglioramento incrementale	54
5.2.3	Soglia ottimale e stabilità: plateau MCC come indicatore di robustezza	55
5.2.4	Importanza delle variabili: traction come quasi-sufficienza empirica	55
5.3	BART day-by-day	56
5.3.1	Perché BART: regressione, incertezza e aggiornamento sequenziale	56
5.3.2	RMSE front-loaded: interpretazione del near-optimal day e del plateau	56
5.3.3	Trasformazione e capping: perché sono utili ma introducono saturazione	57

5.3.4	Diagnostiche: compressione e forma degli errori	57
5.4	RF vs BART: complementarità, non ridondanza	57
5.5	DCA: quando la previsione diventa utile per decidere	58
5.5.1	Perché DCA: evitare soglie arbitrarie e incorporare costi/benefici	58
5.5.2	Perché per $T = 75\%$ emerge utilità precoce	58
5.5.3	Perché per $T = 100\%$ compare NA	58
5.5.4	RMSE vs Net Benefit: perché possono divergere	59
5.6	VOI e stop–waiting: il timing ottimale non è il best day	59
5.6.1	VOI come criterio sequenziale coerente con un costo del tempo	59
5.6.2	Sensibilità a C_{wait} : cosa aspettarsi	60
5.7	Limite metodologico: coverage bassa e calibrazione dell’incertezza . .	60
5.8	Implicazioni pratiche ed estensioni	60
6	Applicazione del framework a <i>Adotta un Sogno</i>	63
6.1	Obiettivo del capitolo	63
6.2	Il contesto: perché “Adotta un Sogno” è un caso rilevante	63
6.3	Dal modello al processo: una strategia informativa in due stadi	64
6.3.1	Stadio 1 — Lancio (EX-ANTE): progettare per massimizzare la trazione iniziale	64
6.3.2	Stadio 2 — Monitoraggio precoce: aggiornare con trazione e decidere	64
6.4	Interventi concreti: cosa fare quando i segnali lo suggeriscono	65
6.4.1	“Rilancio leggero”	65
6.4.2	“Spinta mirata”	66
6.4.3	“Accelerazione”	66
6.5	Perché puntare a target intermedi (e non solo al 100%)	66
6.6	Una proposta operativa di calendario: primi giorni come finestra critica	67
6.7	Trasparenza e misurabilità: come rendere credibile il goal	67
6.8	Limiti e cautele nell’uso decisionale	68
6.9	Chiusura	68
6.10	Perché questa ricerca può effettivamente essere d’aiuto	68
7	Conclusioni	71
7.1	Risultati principali	71
7.1.1	La trazione iniziale domina il contenuto informativo	71
7.1.2	L’apprendimento è front-loaded: quasi tutto “si vede” presto .	72

7.1.3	Ottimo predittivo e ottimo decisionale non coincidono	72
7.2	Contributi metodologici e implicazioni operative	73
7.2.1	Un esperimento causale-informativo sul ruolo della trazione . .	73
7.2.2	Una mappa temporale dell'informazione	73
7.2.3	Un ponte esplicito tra previsione e decisione	73
7.3	Limiti e raccomandazioni per lavori futuri	73
7.3.1	Calibrazione e coverage degli intervalli	73
7.3.2	Eventi rari e metriche più informative	74
7.3.3	Validazione temporale e robustezza	74
7.4	Conclusione finale	74

Bibliografia	75
---------------------	-----------

Ringraziamenti

תודה לסבא ולסבתא

0.1 Abstract

Questa tesi analizza il ruolo dell'informazione dinamica nel determinare la probabilità di successo delle campagne di crowdfunding. L'obiettivo è valutare in che misura l'osservazione della trazione iniziale modifichi il contenuto informativo disponibile rispetto alle sole caratteristiche statiche osservabili ex-ante. Attraverso un confronto sistematico tra modelli predittivi stimati prima del lancio della campagna (EX-ANTE) e modelli stimati al ventesimo giorno (DAY-20), si dimostra che la dinamica precoce della raccolta fondi rappresenta una variabile altamente discriminante. L'analisi evidenzia un cambio strutturale nel regime informativo: mentre le caratteristiche strutturali, testuali ed emozionali presentano potere predittivo limitato in assenza di dinamica osservata, la trazione cumulata nei primi giorni concentra la quasi totalità dell'informazione rilevante. Oltre alla valutazione delle performance tramite metriche robuste per class imbalance, la tesi integra strumenti di Decision Curve Analysis e Value of Information per tradurre la capacità predittiva in raccomandazioni operative. I risultati suggeriscono che gli interventi promozionali debbano essere intensificati nelle fasi iniziali, quando la generazione di trazione può produrre effetti cumulativi e amplificare la probabilità di successo finale.

Capitolo 1

Struttura dei dati, flusso informativo e metodologia

1.1 Introduzione metodologica

L'obiettivo di questa tesi è analizzare e prevedere il successo di campagne di crowdfunding donation-based modellando esplicitamente il flusso di informazioni che si genera nel tempo.

La letteratura economica e manageriale ha evidenziato come il successo nel crowdfunding dipenda da fattori eterogenei: caratteristiche statiche della campagna (goal, durata, qualità del testo), segnali di capitale sociale ([Nahapiet & Ghoshal, 1998](#); [Zheng et al., 2014](#)), dinamiche di early contribution ([Mollick, 2014](#); [Colombo et al., 2015](#)), e meccanismi di signaling ([Spence, 1973](#)).

In particolare, [Mollick \(2014\)](#) mostra che le campagne presentano una dinamica temporale fortemente strutturata: un picco iniziale di raccolta, seguito da una fase di rallentamento e da una possibile coda lunga (*long tail*). Questo andamento suggerisce che l'informazione disponibile ai potenziali donatori evolve progressivamente e modifica le probabilità di successo.

Coerentemente con questa impostazione teorica, l'analisi distingue tre livelli informativi:

- Informazione ex-ante (nota al momento del lancio)
- Informazione testuale e semantica (estratta dal contenuto narrativo)
- Informazione dinamica (early traction osservata nei primi 20 giorni)

La costruzione dei modelli è stata effettuata evitando esplicitamente fenomeni di *data leakage* (Kaufman et al., 2012), cioè l'utilizzo di informazioni non disponibili al momento della previsione.

1.2 Struttura del dataset

Il dataset contiene oltre 5.000 campagne GoFundMe raccolte nel 2023. Le campagne presentano una forte eterogeneità in termini di obiettivi economici, numerosità di donatori e struttura testuale.

1.2.1 Variabili target

Sono state considerate due definizioni di outcome:

- **goal_reached**: variabile binaria (1 se l'obiettivo è raggiunto, 0 altrimenti)
- **share_complete**: rapporto tra raccolta finale e goal

La distribuzione della **share_complete** (Figura 1.1) evidenzia:

- forte asimmetria positiva
- presenza di campagne overfunded ($\text{share} > 1$)
- elevata concentrazione di massa tra 0 e 0.5




Figura 1.1: Distribuzione della **share_complete**

L'asimmetria suggerisce l'adozione di una trasformazione monotona per stabilizzare la varianza e rendere l'outcome più trattabile dal punto di vista modellistico. È stata quindi adottata la trasformazione logaritmica:

$$Y = \log(1 + \text{share_complete})$$

coerentemente con la letteratura sulle trasformazioni di potenza (Box & Cox, 1964; Sakia, 1992).




Figura 1.2: Distribuzione dell'outcome trasformato

La trasformazione comprime la coda superiore e riduce l'eteroschedasticità, facilitando la modellazione non lineare.

1.2.2 Problema di sbilanciamento

La variabile `goal_reached` presenta un marcato sbilanciamento:

- 86.1% campagne non raggiungono il goal
- 13.9% campagne lo raggiungono




Figura 1.3: Distribuzione della variabile target

In presenza di class imbalance, l'accuracy non è informativa ([He & Garcia, 2009](#)). Per questo motivo la valutazione è stata basata su:

- AUC
- Precision-Recall curve ([Saito & Rehmsmeier, 2015](#))
- Matthews Correlation Coefficient (MCC) ([Chicco & Jurman, 2020](#))

L'MCC è particolarmente appropriato poiché incorpora simultaneamente veri positivi, veri negativi, falsi positivi e falsi negativi.

1.3 Variabili statiche

1.3.1 Variabili monetarie

- goal_amount
- campaign_duration
- donor_count (utilizzata solo a fini descrittivi)

La Figura 1.4 mostra una relazione positiva ma chiaramente non lineare tra numero finale di donatori e performance.




Figura 1.4: Numero di donatori e performance

Si osserva:

- forte dispersione per bassi livelli di donatori
- effetto di saturazione oltre determinate soglie
- incremento monotono del tasso di successo per quintile (Figura successiva)

Questo è coerente con la teoria del capitale sociale ([Nahapiet & Ghoshal, 1998](#)).

1.4 Variabili testuali generate

Il contenuto testuale delle campagne rappresenta una componente centrale del processo di raccolta fondi, in quanto costituisce il principale strumento narrativo attraverso cui l'organizzatore comunica bisogno, credibilità e urgenza. La letteratura ha evidenziato come le caratteristiche semantiche e strutturali del testo influenzino significativamente la probabilità di successo ([Babayoff & Shehory, 2022](#); [Lipusch et al., 2023](#)).

Il testo è stato trasformato in un insieme di variabili quantitative riconducibili a tre dimensioni: lunghezza, struttura sintattica e contenuto emotivo.

Lunghezza e struttura

Sono state costruite le seguenti variabili:

- **text_length**: numero totale di caratteri del testo;

- **n_words**: numero totale di parole;
- **n_sentences**: numero di frasi (approssimato tramite segmentazione per punteggiatura);
- **words_per_sentence**: numero medio di parole per frase;
- **chars_per_word**: numero medio di caratteri per parola.

Queste variabili consentono di catturare non solo la quantità di testo, ma anche il *ritmo narrativo* e la complessità sintattica.

Il numero medio di parole per frase (**words_per_sentence**) rappresenta una misura indiretta della densità informativa e della leggibilità: frasi molto lunghe possono riflettere maggiore articolazione argomentativa ma anche minore chiarezza; frasi brevi possono trasmettere urgenza e immediatezza.

Analogamente, il numero medio di caratteri per parola può essere interpretato come sintesi della complessità lessicale.




Figura 1.5: Lunghezza del testo e performance

La Figura 1.5 mostra la relazione tra lunghezza del testo e performance (capped a 1). La correlazione lineare è prossima a zero, suggerendo che la lunghezza in sé non sia sufficiente a spiegare la probabilità di successo. Tuttavia, la dispersione dei punti indica possibili effetti non lineari o interazioni con altre variabili, coerentemente con quanto evidenziato in [Lipusch et al. \(2023\)](#).

Contenuto emotivo

Sono state inoltre costruite variabili legate alla componente emotiva del testo:

- **positive_emotions**: frequenza normalizzata di termini a connotazione positiva;
- **negative_emotions**: frequenza normalizzata di termini a connotazione negativa;
- **emotional_balance**: differenza tra componente positiva e negativa.

La letteratura sul crowdfunding suggerisce che la componente emotiva svolga un ruolo cruciale nella mobilitazione delle donazioni, in quanto attiva meccanismi empatici e prosociali (Mollick, 2014; Babayoff & Shehory, 2022).

L'indice di bilanciamento emotivo (**emotional_balance**) consente di sintetizzare il tono complessivo della narrazione. Un valore positivo indica prevalenza di linguaggio positivo (speranza, gratitudine, resilienza), mentre un valore negativo indica prevalenza di linguaggio orientato al bisogno o alla difficoltà.

Nel complesso, l'inclusione delle variabili strutturali (ritmo, numero di frasi) insieme a quelle emotive consente di superare un approccio puramente quantitativo alla lunghezza del testo, modellando in modo più articolato la qualità narrativa della campagna.

Dal punto di vista metodologico, tali variabili sono particolarmente adatte a modelli non lineari (come Random Forest e BART), poiché l'effetto del ritmo narrativo e del tono emotivo può manifestarsi attraverso soglie o interazioni difficilmente catturabili da modelli lineari tradizionali (Hastie et al., 2009; Kuhn & Johnson, 2013).

1.5 Variabili dinamiche: early traction (1–20 giorni)

Il contributo metodologico principale consiste nella costruzione di variabili cumulative nei primi 20 giorni:

- **pct_goal_cum_d1, ..., d20**
- **donors_cum_d1, ..., d20**

Queste variabili catturano il flusso informativo progressivo.




Figura 1.6: Traiettorie cumulative nei primi 20 giorni

La Figura 1.6 mostra che le campagne di successo divergono già nei primissimi giorni.

Si osserva:

- picco iniziale marcato
- separazione precoce tra successo e insuccesso
- dinamica coerente con [Mollick \(2014\)](#) e [Etter et al. \(2013\)](#)

1.6 Data leakage

Seguendo [Kaufman et al. \(2012\)](#), si è evitato l'utilizzo di:

- `current_amount` finale
- `donor_count` finale nei modelli dinamici
- `share_complete` finale come predittore

Ogni modello al giorno d utilizza esclusivamente informazioni disponibili entro il giorno d ad eccezione della durata totale della campagna la quale si presuppone nota in quanto l'organizzatore stesso dovrebbe decidere a priori quanto tempo donare attivamente per aiutare la causa.

1.7 Scelta dei modelli

Sono stati stimati Random Forest ([Breiman, 2001](#)) e BART.

Random Forest è robusto a:

- non linearità
- interazioni
- multicollinearità

BART fornisce una modellazione completamente bayesiana:

$$Y = \sum_{m=1}^M g(x; T_m, \mu_m) + \epsilon$$

Particolarmente adatto a catturare relazioni non parametriche complesse ([Hastie et al., 2009](#); [Kuhn & Johnson, 2013](#)) e a modellare il flusso di informazione.

1.8 Validazione

La valutazione è stata effettuata tramite K-fold cross-validation ([Kohavi, 1995](#)).

Sono state utilizzate:

- AUC (con confronto DeLong ([DeLong et al., 1988](#)))
- MCC ([Chicco & Jurman, 2020](#))
- Precision-Recall ([Davis & Goadrich, 2006](#))

È stato evitato selection bias secondo ([Cawley & Talbot, 2010](#); [Varma & Simon, 2006](#)).

1.9 Sintesi

L'approccio integra:

- teoria del capitale sociale
- teoria del signaling
- modellazione non parametrica

- controllo rigoroso del leakage
- metriche robuste per dati sbilanciati

Il contributo metodologico principale consiste nella formalizzazione del flusso informativo progressivo e nella quantificazione dell'incremento predittivo generato dall'early traction.

Capitolo 2

Metodologia

2.1 Obiettivo operativo e formulazione del problema

La tesi è guidata da una domanda *operativa* oltre che *predittiva*: dato l'andamento iniziale di una campagna donation-based, *quanto presto* è possibile stimare in modo affidabile la performance finale e *quando* tali stime diventano sufficientemente informative per supportare decisioni (es. interventi di rilancio, comunicazione mirata, riallocazione di risorse, oppure stop).

Formalmente, per ogni campagna i e giorno $d \in \{1, \dots, 20\}$ si osserva un insieme informativo

$$\mathcal{I}_{i,d} = \{\mathbf{x}_{i,\leq d}\},$$

costruito esclusivamente con variabili disponibili entro d . L'obiettivo è duplice:

1. **Predizione continua:** stimare l'esito finale su una scala interpretabile (percentuale di goal raggiunta, cappata a 100);
2. **Decisione a soglia:** derivare probabilità $\pi_i(d, T) = \Pr(\text{pct}_{final,i} \geq T \mid \mathcal{I}_{i,d})$ per target $T \in \{75, 100\}$ e valutare regole di intervento basate su soglie τ .

Questa impostazione è coerente con l'evidenza empirica nel crowdfunding: la trazione iniziale funziona come segnale aggregato e la dinamica è fortemente dipendente dall'avvio (*early traction*) ?Etter et al. (2013); Spence (1973); Colombo et al. (2015); Zheng et al. (2014).

2.2 Vincolo informativo e prevenzione del data leakage

In problemi dinamici la principale fonte di sovrastima è il *data leakage*: l'uso diretto o indiretto di informazione futura produce performance irrealistiche e regole decisionali

non trasferibili [Kaufman et al. \(2012\)](#). Per evitarlo, il dataset è costruito in forma *day-by-day*: per ogni d si creano feature ammissibili solo se osservabili entro d .

2.2.1 Set informativo $\mathcal{I}_{i,d}$

Per ciascun giorno d le feature includono:

- **Statiche (lancio):** goal, durata, categoria, indicatori testuali e (se presenti) emotivi;
- **Trazione cumulata entro d :** `pct_goal_cum_d`, `donors_cum_d`;
- **Dinamica locale:** incrementi giornalieri (es. Δ sulla trazione cumulata) come proxy della velocità.

Sono escluse variabili che codificano lo stato finale o quasi-finale (anche se “mascherate”), perché violerebbero il vincolo informativo [Kaufman et al. \(2012\)](#).

2.3 Validazione out-of-sample e rischio di bias da selezione

Le performance sono stimate *out-of-sample* mediante K -fold cross-validation (CV). Per un fold test di cardinalità N , si calcolano:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}, \quad (2.1)$$

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \quad (2.2)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}. \quad (2.3)$$

È importante distinguere *tuning* e *valutazione*: l’ottimizzazione di iperparametri o soglie sullo stesso campione può introdurre ottimismo [Cawley & Talbot \(2010\)](#). Inoltre, la varianza della k -fold CV non ammette in generale stimatori non distorti, quindi differenze piccole tra modelli/giorni vanno interpretate con cautela [Bengio & Grandvalet \(2004\)](#); [Nadeau & Bengio \(2003\)](#); [Kohavi \(1995\)](#).

2.4 Random Forest: teoria essenziale e setup sperimentale

2.4.1 Principio del metodo

La Random Forest (RF) è un ensemble di alberi di decisione ottenuti tramite *bagging* (bootstrap aggregating) e *decorrelazione* tramite selezione casuale di feature a ogni split [Breiman \(2001\)](#). Indicando con $\hat{h}_b(\mathbf{x})$ il predittore del b -esimo albero ($b = 1, \dots, B$), la previsione è:

$$\hat{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(\mathbf{x}) \quad (\text{classificazione probabilistica})$$

oppure media sulle risposte per regressione. L'aggregazione riduce la varianza rispetto al singolo albero e permette di catturare non-linearità e interazioni senza specificare una forma funzionale [Hastie et al. \(2009\)](#); [James et al. \(2013\)](#).

2.4.2 Disegno dell'esperimento: EX-ANTE vs DAY-20

La RF è usata come esperimento sul *contenuto informativo*:

- **EX-ANTE**: sole feature disponibili al lancio;
- **DAY-20**: EX-ANTE + trazione cumulata entro 20 giorni.

In questo modo si quantifica direttamente il guadagno dovuto all'osservazione della trazione iniziale.

2.4.3 Sbilanciamento, metrica di tuning e scelta della soglia

Nel setting classificatorio (evento di successo), le classi possono essere sbilanciate; in tali casi l'accuracy è poco informativa e si preferiscono metriche che tengono conto dell'intera matrice di confusione. La metrica primaria adottata è il Matthews Correlation Coefficient (MCC), robusto in presenza di imbalance [Chicco & Jurman \(2020\)](#). La soglia di decisione non è fissata a 0.5, ma stimata massimizzando l'MCC su predizioni out-of-fold (OOF), riducendo bias ottimistici legati alla selezione [Cawley & Talbot \(2010\)](#).

2.4.4 Metriche riportate e intervalli di confidenza

Per confrontare i due scenari si riportano:

- **Threshold-free**: AUC ROC;

- **Threshold-dependent:** MCC (alla soglia scelta), balanced accuracy;
- **Qualità probabilistica:** log-loss e Brier score.

L'AUC è accompagnata da intervalli di confidenza stimati con il metodo non parametrico di DeLong [DeLong et al. \(1988\)](#). Per completezza metodologica, si osserva che in presenza di forte imbalance ROC/AUC può essere meno informativa rispetto a metriche precision-recall [Davis & Goadrich \(2006\)](#) (usabili come analisi di sensibilità per target rari).

2.4.5 Interpretabilità: importance e controllo di robustezza

L'importanza delle variabili è stimata con permutation importance (anche aggregata per gruppi), utile per verificare se la struttura predittiva è dominata dalla trazione o se restano contributi delle feature statiche. L'interpretazione è descrittiva (non causale), ma funzionale a diagnosticare quali segnali guidano le previsioni.

2.5 BART day-by-day: modello, trasformazioni e output probabilistici

2.5.1 Modello di regressione

Per ciascun giorno d si stima un modello bayesiano di regressione:

$$y_i = f_d(\mathbf{x}_{i,d}) + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2), \quad (2.4)$$

dove $f_d(\cdot)$ è rappresentata come somma di M alberi:

$$f_d(\mathbf{x}) = \sum_{m=1}^M g(\mathbf{x}; T_m, \boldsymbol{\mu}_m), \quad (2.5)$$

con T_m struttura dell'albero e $\boldsymbol{\mu}_m$ parametri dei terminal nodes. L'idea è che molti alberi “deboli” (con shrinkage/prior su profondità e leaf values) producano una funzione flessibile ma regolarizzata: si catturano non-linearità e interazioni mantenendo controllo sulla complessità, analogamente alla logica degli ensemble, ma in un quadro probabilistico coerente.

2.5.2 Trasformazione dell'outcome e scala interpretabile

L'outcome continuo è trasformato per stabilizzare la varianza e ridurre l'impatto delle code:

$$y = \log(1 + \text{share_complete}).$$

Le previsioni sono riportate su scala percentuale finale (interpretazione manageriale) e cappate a 100:

$$\text{pct}_{final} = \min \{ 100, 100(\exp(y) - 1) \}.$$

L'uso di trasformazioni monotone è coerente con l'idea generale di migliorare proprietà modellistiche e confrontabilità delle metriche [Box & Cox \(1964\)](#); [Sakia \(1992\)](#); [Tukey \(1957\)](#).

2.5.3 Output bayesiano e intervalli predittivi

Il modello produce draw posteriori e quindi una distribuzione predittiva per y (e per pct_{final} dopo back-transform). Questo consente:

- **previsioni puntuali** (media/mediana dei draw);
- **intervalli predittivi** (es. 80%, 95%);
- **probabilità di soglia** $\pi_i(d, T)$ per l'analisi decisionale (Sez. [2.8–2.9](#)).

2.5.4 Diagnostiche dell'incertezza: coverage e width

Sugli intervalli predittivi si valutano:

- **Coverage**: frequenza empirica con cui y_i (o $\text{pct}_{final,i}$) ricade nell'intervallo nominale;
- **Width**: ampiezza media dell'intervallo.

Queste diagnostiche distinguono accuratezza puntuale e calibrazione dell'incertezza, cruciali quando le previsioni alimentano regole decisionali.

2.6 Selezione non arbitraria dei giorni chiave (best, near-optimal, plateau)

Per ogni giorno d si ottiene una metrica media sui fold $M(d) = \text{RMSE}_{pct}(d)$. Per ridurre rumore campionario si applica smoothing e si definisce il guadagno marginale:

$$\Delta(d) = \widetilde{M}(d-1) - \widetilde{M}(d), \quad (2.6)$$

dove $\widetilde{M}$ è la serie smoothed. Si definiscono:

- **Best day:** $d^* = \arg \min_d M(d)$;
- **Near-optimal day:** primo d tale che $M(d) \leq M(d^*)(1 + \varepsilon)$ con $\varepsilon = 0.02$;
- **Plateau day:** primo giorno a partire dal quale $\Delta(d)$ rimane stabilmente piccola (rendimenti marginali decrescenti).

Questa scelta privilegia criteri *pragmatici* e robusti, coerenti con l'idea che differenze piccole tra giorni possano essere dominate dalla variabilità CV [Bengio & Grandvalet \(2004\)](#); [Nadeau & Bengio \(2003\)](#); [Cawley & Talbot \(2010\)](#).

2.7 Dalla regressione alla decisione: probabilità di soglia

Per un target operativo $T \in \{75, 100\}$ si definisce l'evento:

$$E_i(T) = \mathbb{I}\{\text{pct}_{final,i} \geq T\}. \quad (2.7)$$

Dai draw predittivi si stima:

$$\pi_i(d, T) = \Pr(E_i(T) = 1 \mid \mathcal{I}_{i,d}), \quad (2.8)$$

e si considera una regola di intervento basata su soglia τ :

$$\widehat{a}_i(\tau) = \mathbb{I}\{\pi_i(d, T) \geq \tau\}.$$

In questo modo, la previsione continua alimenta direttamente una policy binaria interpretabile.

2.8 Decision Curve Analysis: Net Benefit e robustezza

Per ciascuna soglia τ si calcola il Net Benefit:

$$\text{NB}(\tau) = \frac{\text{TP}(\tau)}{N} - \frac{\text{FP}(\tau)}{N} \cdot \frac{\tau}{1 - \tau}, \quad (2.9)$$

con confronto rispetto alle strategie baseline *treat-all* e *treat-none*. La DCA consente di valutare il modello in termini di utilità (trade-off FP/FN implicito in τ), evitando che la sola accuratezza media (RMSE) determini scelte operative.

2.8.1 Bande al 90% via bootstrap bayesiano e soglie robuste

Per quantificare l'incertezza di $\text{NB}(\tau)$ si costruiscono bande (es. 90%) con resampling (bootstrap) [Efron & Tibshirani \(1993\)](#). Si definiscono:

$$\tau^* = \arg \max_{\tau} \text{NB}(\tau), \quad \tau_{\text{rob}} = \arg \max_{\tau} \text{NB}_{\text{low90}}(\tau),$$

dove NB_{low90} è il lower bound della banda al 90%. Infine, il *primo giorno decisionalmente utile* è:

$$d_{\text{dec}}(T) = \min \left\{ d : \max_{\tau} \mathbb{E}_{\text{fold}} [\text{NB}_{\text{low90}}(d, \tau, T)] > 0 \right\}.$$

2.9 Decisione multistadio: Value of Information e stop-waiting

La scelta è sequenziale: decidere oggi o attendere k giorni. Si definisce una utility prudente:

$$U_{\text{rob}}(d, T) = \max_{\tau} \text{NB}_{\text{low90}}(d, \tau, T), \quad (2.10)$$

e un costo giornaliero dell'attesa C_{wait} . Il valore dell'attesa è:

$$\text{VOI}(d, k, T) = U_{\text{rob}}(d + k, T) - U_{\text{rob}}(d, T) - k \cdot C_{\text{wait}}. \quad (2.11)$$

La regola *stop-waiting* seleziona il primo giorno d tale che

$$\min_{k \in \mathcal{K}} \text{VOI}(d, k, T) \leq 0,$$

con $\mathcal{K}$ insieme di orizzonti considerati (es. $k \in \{1, 2, 3\}$). Operativamente, lo stop-day identifica quando l'informazione addizionale non compensa più, in modo prudente, il costo del tempo.

2.10 Sintesi della pipeline metodologica

La catena metodologica è:

1. costruzione *day-by-day* delle feature e vincolo anti-leakage [Kaufman et al. \(2012\)](#);
2. RF come esperimento EX-ANTE vs DAY-20 con tuning e soglia OOF su MCC [Breiman \(2001\)](#); [Chicco & Jurman \(2020\)](#); [Cawley & Talbot \(2010\)](#);
3. BART day-by-day per previsione continua e probabilità di soglia, con metriche out-of-sample e diagnostiche di incertezza [Box & Cox \(1964\)](#); [Sakia \(1992\)](#);
4. selezione dei giorni chiave con near-optimal e plateau via $\Delta(d)$, coerente con la variabilità CV [Bengio & Grandvalet \(2004\)](#); [Nadeau & Bengio \(2003\)](#);
5. DCA per valore decisionale e VOI per il timing ottimale (stop-waiting), con bande via resampling [Efron & Tibshirani \(1993\)](#).

In questo modo la tesi non si limita a “predire il successo”, ma costruisce un framework coerente per *monitorare* una campagna nel tempo: capire quando la previsione diventa quasi ottimale, quando diventa decisionale (robusta), e quando conviene smettere di attendere dato un costo del tempo.

Capitolo 3

Risultati Random Forest

3.1 Setup sperimentale e validazione

3.1.1 Obiettivo e scenari di confronto

L'obiettivo dell'analisi è quantificare il *guadagno informativo* derivante dall'inclusione della trazione iniziale della campagna rispetto a un set di sole informazioni disponibili al lancio.

Sono stati definiti due scenari:

- **EX-ANTE:** feature strutturali, testuali ed emozionali disponibili al momento del lancio.
- **DAY-20:** feature EX-ANTE + trazione cumulata entro 20 giorni (`pct_goal_cum_d20`, `donors_cum_d20`).

3.1.2 Modello, tuning e gestione dello sbilanciamento

Il modello utilizzato è una Random Forest [Breiman \(2001\)](#), con:

- tuning su griglia mediante cross-validation stratificata a 5 fold,
- ottimizzazione degli iperparametri rispetto alla media del Matthews Correlation Coefficient (MCC),
- gestione dello sbilanciamento tramite class weights,
- selezione della soglia decisionale su predizioni out-of-fold (OOF), al fine di evitare selection bias [Cawley & Talbot \(2010\)](#).

3.1.3 Metriche di valutazione e intervalli di confidenza

L'uso dell'MCC come metrica primaria è motivato dalla sua robustezza in presenza di class imbalance e dalla sua superiorità rispetto a F1 e accuracy in contesti binari sbilanciati [Chicco & Jurman \(2020\)](#).

Le metriche riportate includono:

- MCC (threshold-dependent),
- AUC ROC (threshold-free),
- Balanced Accuracy,
- LogLoss e Brier score (qualità probabilistica).

Gli intervalli di confidenza dell'AUC sono stimati mediante metodo non parametrico di DeLong [DeLong et al. \(1988\)](#).

3.2 Confronto delle performance: EX-ANTE vs DAY-20

3.2.1 Risultati principali sul test set

La Figura 3.1 riporta il confronto delle principali metriche sul test set.



Figura 3.1: MCC vs soglia — DAY-20

I risultati mostrano un incremento marcato nello scenario DAY-20:

- **AUC:** 0.527 [0.474, 0.579] → 0.868 [0.836, 0.901]

- **MCC**: incremento sostanziale (oltre +0.4)
- **Balanced Accuracy**: da circa 0.55 a 0.75
- **LogLoss e Brier**: riduzione significativa.

3.2.2 Interpretazione del salto prestazionale

L'AUC dello scenario EX-ANTE è statisticamente compatibile con una capacità discriminativa quasi casuale (intervallo include valori prossimi a 0.5), mentre lo scenario DAY-20 mostra eccellente capacità discriminativa.

Questo risultato indica che la trazione iniziale contiene informazione predittiva sostanziale non presente nelle sole caratteristiche statiche.

La Figura 3.1 evidenzia una discontinuità netta tra i due scenari, sia in termini di capacità discriminativa sia di qualità probabilistica.

In particolare:

- **AUC**: lo scenario EX-ANTE presenta $AUC = 0.527$ [0.474, 0.579], valore statisticamente compatibile con un classificatore quasi casuale (l'intervallo include 0.5). Al contrario, DAY-20 raggiunge $AUC = 0.868$ [0.836, 0.901], indicando eccellente separabilità tra le classi.
- **MCC**: l'incremento è superiore a +0.4 punti, passando da un valore prossimo a 0.1–0.15 a circa 0.55. Considerata la sensibilità dell'MCC alla struttura completa della matrice di confusione [Chicco & Jurman \(2020\)](#), questo salto implica un miglioramento simultaneo di precision e recall su entrambe le classi.
- **Balanced Accuracy**: l'aumento da circa 0.55 a 0.75 indica una sostanziale riduzione del bias verso la classe maggioritaria.
- **LogLoss e Brier score**: la riduzione marcata in DAY-20 segnala un miglioramento non solo nella classificazione hard, ma anche nella calibrazione e nella qualità probabilistica delle predizioni.

Il risultato non rappresenta un semplice miglioramento incrementale, ma una vera e propria transizione di regime: il modello EX-ANTE è informativamente debole, mentre DAY-20 mostra una struttura predittiva fortemente separabile.

3.3 Ottimizzazione della soglia e MCC

3.3.1 Stima della soglia ottimale su predizioni OOF

La soglia decisionale è stimata massimizzando l'MCC su predizioni OOF nel training.

3.3.2 DAY-20: forma della curva e robustezza del plateau

Nel caso DAY-20 la soglia ottimale è circa $t^* = 0.57$, con MCC superiore a 0.7 in training.

Nella figura successiva relativa all'istante temporale del ventesimo giorno (3.2), la curva MCC in funzione della soglia mostra:

- crescita monotona fino a circa $t \approx 0.5$,
- un plateau stabile tra 0.55 e 0.65,
- massimo globale in corrispondenza di $t^* = 0.57$.




Figura 3.2: MCC vs soglia — DAY-20

L'ampiezza del plateau suggerisce robustezza della regola decisionale: piccole variazioni della soglia non producono deterioramenti significativi della performance.

Questo comportamento è tipico di modelli con buona separazione tra distribuzioni delle probabilità predette per le due classi.




Figura 3.3: MCC vs soglia — EX-ANTE

3.3.3 EX-ANTE: soglia più fragile e bassa separazione

Nel caso EX-ANTE la soglia ottimale è circa $t^* = 0.33$, con MCC massimo inferiore a 0.3.

La differenza suggerisce che, anche fissando una regola operativa ottimale, il modello EX-ANTE rimane intrinsecamente poco informativo.

Nel caso EX-ANTE (3.3), la curva MCC presenta:

- massimo relativamente basso ($t^* = 0.33$),
- andamento meno stabile,
- declino rapido oltre soglie moderate.

L'assenza di un plateau indica che il modello non genera una separazione probabilistica netta tra classi. La soglia ottimale si colloca in un'area di compromesso fragile, coerente con una distribuzione delle probabilità fortemente sovrapposta.

3.4 Capacità discriminativa: curve ROC

Le curve ROC (3.5, 3.4) mostrano una differenza strutturale nella geometria della classificazione.

3.4.1 DAY-20

Nel modello DAY-20:

- la curva è fortemente convessa verso l'angolo in alto a sinistra,

- la pendenza iniziale è elevata,
- la separazione tra classi è evidente lungo quasi tutto il dominio.

L'AUC = 0.868 indica che la probabilità che un'osservazione positiva riceva score maggiore di una negativa è prossima all'87%.

3.4.2 EX-ANTE

Nel modello EX-ANTE:

- la curva segue approssimativamente la diagonale casuale,
- l'AUC = 0.527 non differisce sostanzialmente da 0.5,
- la capacità di ranking è marginale.

Sebbene la ROC possa essere meno sensibile in presenza di imbalance [Davis & Goadrich \(2006\)](#), la coerenza tra ROC, MCC e metriche probabilistiche rafforza la robustezza del risultato.




Figura 3.4: ROC (TEST) — EX-ANTE

La curva ROC del modello DAY-20 mostra una separazione netta tra classi. Al contrario, la curva EX-ANTE è prossima alla diagonale casuale.




Figura 3.5: ROC (TEST) — DAY-20

In presenza di class imbalance, si sottolinea che la ROC può essere meno informativa rispetto alla PR-curve [Davis & Goadrich \(2006\)](#); tuttavia, il miglioramento simultaneo di MCC, AUC e metriche probabilistiche rende il risultato robusto.

3.5 Importanza delle variabili

3.5.1 Aggregazione per gruppi

L'analisi della permutation importance aggregata per gruppi di feature evidenzia una marcata differenza strutturale tra il modello EX-ANTE e il modello DAY-20.

Nel modello DAY-20 (Figura 3.5), il gruppo *Early traction (cumulata)* domina in maniera quasi monopolistica la struttura predittiva. La somma delle importance associate a tale gruppo è di un ordine di grandezza superiore rispetto a qualsiasi altro gruppo di variabili.

Questo risultato suggerisce che la dinamica osservata nei primi 20 giorni costituisca un'informazione altamente sufficiente rispetto all'esito finale della campagna. In termini statistici, la trazione iniziale si comporta come una quasi-sufficient statistic: una volta osservata la progressione iniziale del funding, l'informazione contenuta nelle caratteristiche statiche (strutturali, testuali ed emozionali) diventa largamente marginale.




Figura 3.6: Importanza aggregata per gruppo — DAY-20

L'evidenza è coerente con la letteratura sulle dinamiche cumulative nel crowd-funding. Studi precedenti mostrano che le decisioni degli early backers generano meccanismi di *herding* e *informational cascades*, amplificando la probabilità di ulteriori contributi [Mollick \(2014\)](#); [Etter et al. \(2013\)](#); [Kuppuswamy & Bayus \(2017\)](#). In questo contesto, la trazione iniziale non rappresenta semplicemente un indicatore descrittivo, ma un segnale pubblico che coordina le aspettative degli investitori successivi.

Nel modello EX-ANTE, al contrario, l'importanza è distribuita principalmente tra feature strutturali (dimensione dell'obiettivo e durata), metriche testuali e indicatori emozionali. Tuttavia, i livelli assoluti di importance risultano significativamente inferiori rispetto alla traction nel modello dinamico.

Ciò suggerisce che, prima dell'osservazione della dinamica temporale, il problema predittivo si caratterizzi per una separazione debole delle classi. Le feature disponibili operano come segnali imperfetti della qualità latente del progetto e sono soggette a eterogeneità non osservata. In termini informativi, il modello EX-ANTE si colloca in un regime di elevata incertezza, in cui nessuna dimensione singola riesce a concentrare il potere discriminativo.

Il confronto tra i due modelli evidenzia quindi un vero e proprio cambio di regime informativo: l'introduzione della dinamica temporale precoce trasforma un problema con segnale frammentato e diffuso in uno dominato da poche variabili ad alta capacità esplicativa.

Nel modello DAY-20, il gruppo *Early traction (cumulata)* domina nettamente, con contributo superiore a qualsiasi altro gruppo.

Nel modello EX-ANTE, l'importanza è distribuita principalmente tra:

- feature strutturali (log_goal_amount, durata),
- metriche testuali di lunghezza,
- indicatori emozionali.

Tuttavia, i livelli assoluti di importanza sono significativamente inferiori rispetto alla traction nel modello dinamico.

Questo suggerisce che tali variabili, pur statisticamente rilevanti, non contengono sufficiente informazione discriminativa per generare separazione robusta delle classi.




Figura 3.7: Importanza aggregata per gruppo — EX-ANTE

Nel modello EX-ANTE, le feature strutturali e testuali risultano relativamente più rilevanti, ma con contributi molto inferiori rispetto alla traction nello scenario dinamico.

3.5.2 Top feature

L'analisi delle singole feature consente di comprendere in modo più granulare quali variabili guidino la capacità predittiva dei due modelli.

Modello DAY-20 Nel modello DAY-20 (Figura 3.8), la variabile con importanza nettamente dominante è `pct_goal_cum_d20`. La distanza rispetto a tutte le altre feature è sostanziale, indicando che tale variabile concentra una quota molto elevata dell'informazione discriminativa.

Essa misura la percentuale di obiettivo già raggiunta entro i primi 20 giorni e sintetizza simultaneamente:

- la velocità di accumulazione del capitale,
- l'intensità della domanda iniziale,
- la qualità percepita del progetto,
- la credibilità del segnale generato dagli early backers.

In termini informativi, `pct_goal_cum_d20` rappresenta una misura diretta dell'aggiornamento collettivo delle aspettative: una quota elevata raggiunta in fase iniziale riduce drasticamente l'incertezza residua sull'esito finale.

La seconda variabile per importanza è `donors_cum_d20`. Rispetto alla percentuale raccolta, questa misura cattura la dimensione estensiva del sostegno (numero di sostenitori) piuttosto che quella intensiva (ammontare raccolto). Il fatto che entrambe risultino rilevanti indica che non conta soltanto quanto capitale venga raccolto, ma anche quanto sia diffuso il consenso. Un numero elevato di donatori può infatti amplificare gli effetti di social proof.

Segue `log_goal_amount`, prima tra le variabili strutturali. Anche nel modello dinamico, la dimensione dell'obiettivo mantiene un ruolo non trascurabile: obiettivi più elevati possono essere associati a maggiore ambizione o qualità percepita, ma anche a maggiore rischio. L'effetto logaritmico suggerisce una relazione proporzionale e non lineare.

La quarta variabile è `campaign_duration`. La durata influisce sulla finestra temporale disponibile per raccogliere fondi e può riflettere strategie differenti: campagne più brevi possono segnalare sicurezza e urgenza, mentre campagne più lunghe possono indicare maggiore incertezza o necessità di tempo per mobilitare la rete.

Tra le prime sette compare poi `sadness`, prima variabile emozionale raw. La sua presenza suggerisce che il contenuto emotivo continui a fornire informazione additiva, sebbene su scala molto inferiore rispetto alla traction. L'emozione può agire come leva narrativa, influenzando il coinvolgimento, ma il suo contributo resta marginale una volta osservata la dinamica reale del funding.

Seguono `text_length` e `emotional_balance`. La lunghezza del testo può riflettere il livello di dettaglio o impegno comunicativo del promotore; tuttavia, l'importanza contenuta indica che tali elementi incidono solo marginalmente quando è disponibile informazione dinamica. L'equilibrio emotivo fornisce una misura sintetica del tono complessivo, ma con potere discriminativo limitato.

Complessivamente, nel modello DAY-20 le prime due variabili (`traction` cumulata) dominano nettamente, mentre tutte le altre feature assumono un ruolo secondario e residuale. Questo pattern è coerente con un regime informativo in cui l'osservazione del comportamento aggregato sostituisce gran parte dell'informazione statica.




Figura 3.8: Top feature — DAY-20

Modello EX-ANTE Nel modello EX-ANTE (Figura 3.9), la struttura è radicalmente diversa. La variabile più rilevante è `log_goal_amount`. In assenza di dinamica osservata, la dimensione dell'obiettivo rappresenta il principale segnale strutturale disponibile. Un goal elevato può essere interpretato come indicatore di ambizione, scala del progetto o qualità percepita, ma anche di maggiore rischio di fallimento.

La seconda variabile per importanza è `sadness`. Il fatto che un indicatore emozionale emerga tra le prime posizioni suggerisce che, in fase EX-ANTE, la componente narrativa ed emotiva diventi relativamente più rilevante. In mancanza di evidenza comportamentale, gli investitori possono fare maggiore affidamento su segnali comunicativi.

Segue **emotional_balance**, che sintetizza il tono complessivo del testo. Un equilibrio emotivo specifico può influenzare la percezione di autenticità o credibilità del promotore.

text_length occupa una posizione intermedia: la lunghezza del testo può riflettere completezza informativa, trasparenza o sforzo comunicativo. Tuttavia, l'assenza di predominanza netta indica che tale variabile non è sufficiente, da sola, a generare forte separazione tra classi.

campaign_duration mantiene un ruolo rilevante anche in questo modello, confermando che la struttura temporale pianificata della campagna influisce sulla probabilità di successo.

Tra le prime sette compaiono inoltre **parole_per_frase** e **gratitude**. La prima cattura la complessità sintattica del testo, potenzialmente associata a livello di formalità o chiarezza; la seconda misura un'emozione specifica che può favorire coinvolgimento empatico. Tuttavia, le loro importance restano contenute e distribuite.

Nel complesso, nel modello EX-ANTE l'importanza è frammentata tra più dimensioni — strutturali, testuali ed emozionali — senza una variabile dominante. Ciò riflette un contesto informativo caratterizzato da maggiore incertezza: in assenza di dati dinamici, il modello si affida a una combinazione di segnali deboli e parzialmente correlati.




Figura 3.9: Top feature — EX-ANTE

Interpretazione comparativa Il confronto tra le due strutture di importanza conferma che la trazione iniziale non agisce come semplice covariata aggiuntiva, ma modifica radicalmente la gerarchia informativa del problema.

Nel modello EX-ANTE l'informazione è distribuita e nessuna variabile domina; nel modello DAY-20, invece, poche variabili dinamiche concentrano la quasi totalità del potere discriminativo. Il passaggio da EX-ANTE a DAY-20 corrisponde quindi a una trasformazione del problema da regime ad alta incertezza e segnale diffuso a regime a segnale concentrato e forte separabilità tra classi.

La dinamica temporale precoce si configura dunque come una quasi-sufficiente statistica del successo finale, incorporando e superando l'informazione contenuta nelle caratteristiche statiche.

Capitolo 4

Risultati BART

Questo capitolo presenta e interpreta i risultati ottenuti con l’approccio *day-by-day* basato su BART, stimando un modello distinto per ciascun giorno $d = 1, \dots, 20$ utilizzando esclusivamente l’informazione disponibile entro d (feature statiche e trazione cumulata/early traction). L’obiettivo è duplice: (i) quantificare come l’accuratezza predittiva evolva nel tempo e identificare giorni “chiave”; (ii) valutare se e quando le previsioni producano un vantaggio operativo tramite strumenti decisionali (Decision Curve Analysis e Value of Information). In tutto il capitolo, le metriche sono stimate *out-of-sample* tramite cross-validation (media sui fold), e la variabile target è interpretata sulla scala percentuale finale di completamento del goal, *cappata a 100* per mantenere l’interpretabilità.

4.1 Impostazione del problema e metriche

Per ogni giorno d si stima un BART di regressione sul target trasformato

$$y = \log(1 + \text{share_complete}),$$

e si riporta la qualità anche su una scala direttamente interpretabile:

$$\text{pct}_{final} = \min\{100, 100(\exp(y) - 1)\}.$$

La metrica principale di confronto tra i giorni è RMSE_{pct} , ossia l’RMSE sulla percentuale finale cappata a 100. A complemento vengono riportati MAE, R^2 e diagnostiche di incertezza (coverage e ampiezza media dell’intervallo predittivo al 95%).

4.2 Accuratezza predittiva day-by-day e giorni chiave

4.2.1 Andamento dell'errore e identificazione dei giorni chiave

La Figura 4.1 mostra l'andamento di RMSE_{pct} lungo $d = 1, \dots, 20$. Il profilo è chiaramente “front-loaded”: l'errore diminuisce rapidamente nei primi giorni e poi continua a ridursi con pendenza via via più contenuta.

Dalla curva si identificano tre giorni chiave che verranno usati come riferimento nel seguito:

- **Best day:** $d^* = 20$, giorno con RMSE_{pct} minimo.
- **Near-optimal day:** $d = 9$, primo giorno entro il 2% dal best.
- **Plateau day:** $d = 16$, inizio di una regione di rendimenti marginali stabilmente ridotti.

L'interpretazione operativa è importante: il *best day* massimizza l'accuratezza ma richiede l'attesa completa della finestra; il *near-optimal day* rappresenta invece un compromesso tra tempestività e qualità predittiva, perché già al giorno 9 si ottiene una performance molto vicina al minimo osservabile; il *plateau day* segnala che, oltre un certo punto, l'informazione aggiuntiva diventa sistematicamente poco rilevante in termini di riduzione dell'errore.




Figura 4.1: BART day-by-day: RMSE sulla percentuale finale di completamento (cappata a 100). Linea tratteggiata: serie smoothed; linea verticale: near-optimal day (day 9).

La Figura 4.1 evidenzia un profilo chiaramente “front-loaded” dell’apprendimento predittivo: l’errore out-of-sample diminuisce in modo marcato nei primi giorni, segnalando che la trazione iniziale incorpora una quota rilevante dell’informazione sulla domanda latente. Successivamente, il miglioramento si attenua e la curva entra in una regione di rendimenti marginali decrescenti, fino a un plateau informativo (day 16).

Questo pattern è coerente sia con la teoria statistica dell’apprendimento, secondo cui feature altamente informative producono rapide riduzioni dell’errore di generalizzazione (Hastie et al. (2009)), sia con la letteratura sul crowdfunding che documenta il ruolo della social proof e del capitale sociale iniziale nel determinare le traiettorie di successo (Mollick (2014); Colombo et al. (2015); Spence (1973)).

La distanza ridotta tra near-optimal day (9) e best day (20) suggerisce che gran parte dell’informazione utile è già disponibile nella prima metà dell’orizzonte osservato, con implicazioni rilevanti per decisioni tempestive.

4.2.2 Guadagno informativo marginale e rendimenti decrescenti

Per rendere esplicito *quando* un giorno aggiuntivo aggiunge informazione utile, la Figura 4.2 riporta il guadagno informativo marginale

$$\Delta(d) = M(d-1) - M(d),$$

dove $M(d)$ è l’RMSE medio (smoothed) al giorno d . Valori positivi elevati indicano che osservare un giorno in più produce un miglioramento sostanziale; valori prossimi allo zero indicano che l’incremento informativo è trascurabile.

Il profilo di $\Delta(d)$ conferma la lettura della Figura 4.1: i guadagni più grandi si concentrano nei primissimi giorni, poi decadono rapidamente e si stabilizzano su valori piccoli. Questo comportamento è coerente con una dinamica in cui la trazione iniziale (percentuale raccolta, donazioni, segnali cumulati) incorpora presto una parte significativa dell’informazione sulla domanda latente e sulla capacità di diffusione della campagna; i giorni successivi tendono ad aggiungere informazione più ridondante, generando rendimenti marginali decrescenti. In tale quadro, il *plateau day* (day 16) è interpretabile come l’ingresso in una regione in cui l’attesa produce miglioramenti medi sistematicamente piccoli.




Figura 4.2: Guadagno informativo marginale $\Delta(d)$ su RMSE_pct (smoothed), definito come $\Delta(d) = M(d-1) - M(d)$. Valori più alti indicano giorni con maggiore incremento informativo; dopo circa day 16 si osservano rendimenti decrescenti coerenti con un plateau.

4.3 Diagnostiche di previsione: struttura dell'errore e incertezza

4.3.1 Calibrazione dell'incertezza: coverage al 95%

La Figura 4.3 riporta la *coverage* empirica degli intervalli predittivi nominali al 95% sulla scala percentuale cappata (media sui fold). In un modello ben calibrato, la coverage dovrebbe essere prossima a 0.95. Qui, invece, la coverage rimane stabilmente molto inferiore (circa 0.30–0.38) lungo tutto l'orizzonte temporale, con una lieve crescita iniziale e poi una stabilizzazione.

Questo risultato implica che gli intervalli predittivi risultano *sotto-coperti* (troppo stretti rispetto alla variabilità empirica). Un elemento chiave è che tale sotto-copertura non peggiora con d : l'aggiunta di informazione temporale migliora l'accuratezza puntuale (Figura 4.1) ma non corregge automaticamente la rappresentazione dell'incertezza. Una spiegazione coerente con la costruzione degli intervalli è che essi derivino principalmente dalle draw posteriori della funzione latente BART e non da una *posterior predictive* completa che propaghi esplicitamente il rumore di osservazione; inoltre, trasformazioni non lineari (log/exp) e la cappatura a 100 possono comprimere le code e rendere più difficile ottenere una copertura nominale sulla scala finale.

Operativamente, questa evidenza suggerisce che le quantità probabilistiche del modello sono particolarmente utili come *score* comparativo (ranking) o per regole basate su soglie (DCA/VOI), mentre un'interpretazione “assoluta” degli intervalli al 95% sulla scala capped richiede cautela.




Figura 4.3: Coverage empirica dell’intervallo predittivo nominale al 95% in scala percentuale cappata (media sui fold). Valori vicini a 0.95 indicherebbero incertezza ben calibrata; i risultati mostrano sotto-copertura persistente.

4.3.2 Predetto vs vero nei giorni chiave: errori residui e saturazione

La Figura 4.4 confronta valori predetti e osservati della percentuale finale cappata, nei giorni chiave $d = 9$ e $d = 16$ (fold 1, a scopo illustrativo). La diagonale tratteggiata rappresenta la previsione perfetta ($y = x$). Già al giorno 9 emerge una relazione positiva chiara tra osservato e predetto, segnale che il modello cattura una parte rilevante della struttura informativa in una fase relativamente precoce. Al giorno 16 la nube dei punti appare solo leggermente più concentrata attorno alla diagonale: il miglioramento è presente ma prevalentemente marginale, coerentemente con la logica near-optimal/plateau emersa da RMSE e $\Delta(d)$.

Due aspetti strutturali risultano evidenti:

- **Compressione verso valori intermedi.** Le previsioni tendono a essere meno estreme dei valori osservati, con una contrazione verso il centro. È un comportamento tipico di modelli regolarizzati/ensemble (come BART), che

riducono la varianza predittiva a favore della generalizzazione, ma possono “smussare” gli estremi.

- **Effetto della cappatura (0 e 100).** Si osservano molte realizzazioni concentrate sui valori limite, in particolare vicino a 100. Questo riflette la definizione della variabile risposta e rende intrinsecamente più difficile distinguere campagne altamente performanti (tutte “schiazzate” a 100), aumentando la dispersione verticale in prossimità del bordo.

Nel complesso, la figura supporta l’idea che gran parte dell’informazione utile sia già presente entro il day 9, mentre l’attesa fino al plateau day produce raffinamenti quantitativi contenuti.




Figura 4.4: Predetto vs vero (percentuale finale cappata) nei giorni chiave $d = 9$ e $d = 16$ (fold 1). La diagonale tratteggiata indica previsione perfetta.

4.4 Sintesi numerica delle performance predittive

4.4.1 Metriche sui giorni chiave (near-optimal, plateau, best)

La Tabella 4.1 confronta le metriche principali per $d = 9$, $d = 16$ e $d = 20$. Le differenze sono contenute: l’RMSE_pct scende da 27.61 (day 9) a 27.10 (day 20) e anche il MAE si riduce leggermente; l’ R^2 rimane sostanzialmente stabile (circa 0.43–0.44), indicando che la quota di variabilità spiegata non aumenta in modo rilevante con l’attesa di ulteriori giorni. Anche le metriche di incertezza (coverage e ampiezza media dell’intervallo) variano poco, coerentemente con la stabilità della sotto-copertura discussa in Figura 4.3.

Questa evidenza quantifica il significato pratico del near-optimal day: anticipare la decisione al giorno 9 comporta una perdita di accuratezza limitata rispetto al best day, a fronte di un guadagno temporale significativo.

Tabella 4.1: Performance predittiva sui giorni chiave (media sui fold).

day	rmse_pct	mae_pct	r2_y	cov95_pct	wid95_pct
9	27.6106	21.4256	0.4386	0.3767	25.4876
16	27.3450	21.1835	0.4340	0.3769	25.5037
20	27.1000	20.9278	0.4380	0.3701	24.3393

4.4.2 Top 10 giorni per RMSE_pct: “piattezza” della parte alta

La Tabella 4.2 riporta i dieci giorni con RMSE_pct più basso. I giorni finali (16–20) dominano la classifica, coerentemente con il miglioramento graduale dell’errore; tuttavia l’escursione dei valori è ristretta (circa 27.10–27.61) e anche MAE, R^2 e metriche di incertezza rimangono stabili. In particolare, il day 9 rientra nella top 10 pur essendo molto più precoce dei giorni finali. Questa “piattezza” empirica è la manifestazione quantitativa dei rendimenti decrescenti: attendere oltre i giorni chiave produce miglioramenti marginali piccoli, spesso difficili da giustificare in contesti operativi in cui il tempo ha un costo.

Tabella 4.2: Top 10 giorni per accuratezza predittiva (RMSE_pct più basso).

day	rmse_pct	mae_pct	cov95_pct	wid95_pct	r2_y	rmse_y
20	27.1000	20.9278	0.3701	24.3393	0.4380	0.2951
19	27.1819	21.0995	0.3702	24.5993	0.4418	0.2940
17	27.1985	21.0749	0.3873	25.3839	0.4355	0.2951
18	27.2393	20.9972	0.3783	24.8903	0.4358	0.2971
16	27.3450	21.1835	0.3769	25.5037	0.4340	0.2964
13	27.3884	21.2619	0.3695	24.6667	0.4363	0.2962
15	27.4123	21.1808	0.3716	25.0202	0.4402	0.2956
14	27.4725	21.3465	0.3776	25.8760	0.4328	0.2974
12	27.5323	21.4089	0.3699	25.2587	0.4373	0.2958
9	27.6106	21.4256	0.3767	25.4876	0.4386	0.2961

4.5 Risultati decisionali: Decision Curve Analysis (DCA)

4.5.1 Dal modello continuo all'evento operativo e definizione del beneficio netto

Per connettere previsione e decisione, l'esito viene tradotto in un evento binario:

$$\mathbb{I}\{\text{pct}_{final} \geq T\}, \quad T \in \{75, 100\}.$$

In ciascun giorno d , il modello fornisce una probabilità

$$\pi_i(T) = \Pr(\text{pct}_{final,i} \geq T \mid X_{\leq d}),$$

e si considera una regola del tipo “intervieni se $\pi_i(T) \geq \tau$ ”.

Significato operativo della policy. Nel contesto applicativo di questa tesi, la “policy” non è una decisione di donazione, bensì una regola di intervento gestionale sulla campagna. Attivare la policy su una campagna significa adottare un'azione operativa basata sulla probabilità predetta dal modello. Esempi plausibili includono: promuovere la campagna in evidenza sulla piattaforma, allocare budget pubblicitario aggiuntivo, inviare comunicazioni mirate ai potenziali donatori, fornire supporto strategico al fundraiser, oppure, al contrario, decidere di non investire ulteriori risorse.

Formalmente, la policy è definita come:

$$a_i(d, \tau, T) = \mathbb{I}\{\pi_i(d, T) \geq \tau\},$$

ossia si interviene sulla campagna i al giorno d se la probabilità stimata di raggiungere almeno la soglia T supera il livello decisionale τ .

In questo senso, la Decision Curve Analysis non valuta semplicemente la qualità predittiva del modello, ma il valore incrementale di una strategia di allocazione delle risorse guidata dalle probabilità stimate.

La Decision Curve Analysis valuta il beneficio netto (*Net Benefit*, NB) della regola al variare di τ , confrontandolo con due baseline: *treat-all* (intervenire su tutti) e *treat-none* (non intervenire su nessuno). La banda al 90% (Bayesian bootstrap) permette una lettura prudente della robustezza del vantaggio.

4.5.2 Primo giorno decisionalmente utile

Adottando un criterio conservativo, si definisce il primo giorno decisionalmente utile d_{dec} come il primo giorno per cui esiste almeno una soglia τ tale che il limite inferiore al 90% del beneficio netto medio sui fold (NB_{low90}) sia positivo. La Tabella 4.3 sintetizza il risultato: per $T = 75\%$ il modello diventa utile già al giorno 2; per $T = 100\%$ non emerge alcun giorno con beneficio netto robustamente positivo.

Questa asimmetria è coerente con la maggiore difficoltà del target $T = 100\%$: l'evento è più raro e più vicino alla regione di saturazione della variabile cappata, dove separare in modo affidabile le campagne “molto performanti” è intrinsecamente più complesso.

Tabella 4.3: Primo giorno decisionalmente utile d_{dec} per ciascun target T (criterio: NB_{low90} medio sui fold > 0 per almeno una soglia τ).

Target T	d_{dec}
75%	2
100%	NA

4.5.3 Curve decisionali nei giorni chiave: lettura qualitativa

Le Figure 4.5–4.8 riportano le curve decisionali per i giorni chiave (day 9 e day 16) e per i due target. La lettura si concentra su: (i) segno e ampiezza del NB; (ii) confronto con treat-all/treat-none; (iii) robustezza rispetto alla banda al 90%.

Target $T = 75\%$. Al giorno 9 (Figura 4.5) la curva del modello mostra un vantaggio (NB positivo) su un intervallo di soglie, e la banda al 90% è spesso sopra lo zero nelle regioni più favorevoli, indicando che il guadagno è presente e relativamente robusto. Al giorno 16 (Figura 4.6) il profilo tende ad appiattirsi: il beneficio netto non cresce in modo proporzionale all’attesa e, soprattutto, la robustezza può ridursi (banda che si avvicina allo zero). Questo comportamento è coerente con il plateau informativo osservato nelle figure predittive: aggiungere giorni può migliorare leggermente l’accuratezza, ma non necessariamente aumenta il guadagno decisionale in modo stabile.




Figura 4.5: Decision Curve Analysis al giorno 9 per $T = 75\%$. Linea: NB del modello; banda: IC 90% (Bayesian bootstrap); tratteggiata: treat-all; baseline orizzontale: treat-none.




Figura 4.6: Decision Curve Analysis al giorno 16 per $T = 75\%$. Rispetto al day 9 la curva tende ad appiattirsi, coerentemente con rendimenti marginali decrescenti.

Target $T = 100\%$. Al giorno 9 e al giorno 16 (Figure 4.7 e 4.8) il NB resta tipicamente vicino a zero e la banda include ampie regioni non positive: non emerge un vantaggio decisionale robusto rispetto alle baseline. Questo risultato è coerente

con $d_{dec} = NA$ e con la natura dell'evento $T = 100\%$, più raro e più difficile da predire in modo sufficientemente affidabile per supportare decisioni operative.




Figura 4.7: Decision Curve Analysis al giorno 9 per $T = 100\%$. Il beneficio netto risulta in generale vicino a zero e raramente robusto rispetto alle baseline.




Figura 4.8: Decision Curve Analysis al giorno 16 per $T = 100\%$. Anche con più informazione temporale non emerge un vantaggio decisionale robusto.

4.5.4 Sintesi numerica DCA nei giorni chiave

La Tabella 4.4 riporta le principali quantità decisionali stimate tramite Decision Curve Analysis per i giorni chiave e per i due target considerati ($T = 75\%$ e $T = 100\%$).

Tabella 4.4: Sintesi numerica DCA sui giorni chiave (media sui fold). τ^* : soglia che massimizza il NB medio; τ_{rob} : soglia massima con $\text{NB}_{\text{low}90} > 0$; NB^* e NB_{rob} : benefici netti corrispondenti; prevalenza: frequenza media dell’evento; $\text{treat rate}_{\text{rob}}$: quota di campagne trattate con τ_{rob} .

day	T	τ^*	τ_{rob}	NB^*	NB_{rob}	prevalenza	$\text{treat rate}_{\text{rob}}$
9	75	0.7267	0.1800	0.0011	0.0001	0.1313	0.7652
9	100	0.5200	0.1200	0.0004	0.0000	0.0440	0.7660
16	75	0.6600	0.3800	0.0030	0.0000	0.1313	0.4555
16	100	0.5500	0.2000	0.0012	0.0000	0.0440	0.5670

Significato delle colonne e lettura strutturale della tabella. La colonna *day* indica il giorno informativo d in cui la probabilità $\pi_i(d, T)$ è calcolata, mentre T definisce la soglia sull’outcome reale (evento $\text{pct}_{\text{final}} \geq T$). Le colonne τ^* e τ_{rob} riguardano invece la soglia decisionale applicata alla probabilità predetta. In particolare, τ^* è la soglia che massimizza il beneficio netto medio sui fold, quindi rappresenta la scelta ottimale in senso puntuale; τ_{rob} è invece la soglia più alta per cui il limite inferiore al 90% del NB resta positivo, e rappresenta quindi una scelta prudente che tiene conto dell’incertezza stimata tramite bootstrap.

Le colonne NB^* e NB_{rob} riportano il beneficio netto corrispondente alle due soglie. NB^* misura il massimo vantaggio medio ottenibile rispetto alle strategie *treat-all* e *treat-none*, mentre NB_{rob} rappresenta il beneficio “garantito” in senso conservativo. La *prevalenza* è la frequenza empirica dell’evento nel campione (quota di campagne che effettivamente raggiungono almeno T), grandezza fondamentale perché il Net Benefit dipende strutturalmente dal numero potenziale di veri positivi ottenibili. Infine, il *treat rate_{rob}* indica la quota di campagne su cui la policy robusta si attiva, cioè la percentuale di campagne per cui $\pi_i(d, T) \geq \tau_{\text{rob}}$. Questa colonna traduce la regola decisionale in un’intensità operativa concreta: quante campagne vengono effettivamente “trattate” (cioè oggetto di intervento gestionale).

Interpretazione congiunta delle grandezze decisionali. La tabella deve essere letta come un sistema coerente di grandezze interdipendenti. La prevalenza condiziona la scala massima del NB: eventi più rari (come $T = 100\%$) limitano il numero di veri positivi ottenibili e quindi comprimono il beneficio netto potenziale. Le soglie

τ^* tendono a essere più elevate quando il modello riesce a produrre probabilità ben separate (caso $T = 75\%$), mentre in presenza di eventi rari o probabilità concentrate su valori bassi (caso $T = 100\%$) la soglia che massimizza il NB si colloca su livelli inferiori. La differenza tra τ^* e τ_{rob} misura invece la stabilità del vantaggio: scostamenti ampi indicano che il massimo puntuale è sensibile alla variabilità tra fold e che, per garantire un beneficio robusto, è necessario adottare una policy meno selettiva. Il $\text{treat rate}_{\text{rob}}$ completa l'interpretazione mostrando il costo operativo implicito della scelta prudente: soglie più basse implicano un numero maggiore di campagne trattate, ossia un impiego più esteso di risorse per ottenere un vantaggio netto, anche se modesto.

Dunque ricapitolando, la soglia T definisce l'evento sull'outcome reale: $T = 75\%$ indica il raggiungimento di almeno il 75% del goal finale, mentre $T = 100\%$ rappresenta il pieno completamento. La soglia τ è invece applicata alla probabilità predetta $\pi_i(d, T)$ e governa quanto la regola decisionale sia conservativa: valori più alti implicano maggiore richiesta di confidenza prima di intervenire.

Effetto della prevalenza. La prevalenza dell'evento è circa 13% per $T = 75\%$ e circa 4% per $T = 100\%$. Questa differenza è determinante per comprendere i valori di NB. Poiché il Net Benefit dipende dal numero di veri positivi ottenibili rispetto ai falsi positivi penalizzati, eventi rari limitano strutturalmente il beneficio massimo raggiungibile. Nel caso $T = 100\%$, la rarità dell'evento riduce il numero potenziale di veri positivi e rende più difficile ottenere un vantaggio decisionale stabile rispetto alle strategie *treat-all* o *treat-none*.

Interpretazione delle soglie e differenze tra $T = 75\%$ e $T = 100\%$. Per $T = 75\%$, al day 9 la soglia che massimizza il beneficio netto medio è relativamente elevata ($\tau^* \approx 0.73$). Questo significa che, in media, il NB è massimizzato intervenendo solo quando la probabilità predetta di raggiungere almeno il 75% del goal è molto alta. La ragione è che l'evento ha una prevalenza moderata (circa 13%) e il modello riesce a produrre una separazione relativamente informativa: esiste quindi una regione di probabilità elevate in cui il rapporto tra veri positivi e falsi positivi è favorevole.

Tuttavia, quando si introduce la robustezza (lower bound al 90%), la soglia scende drasticamente ($\tau_{\text{rob}} \approx 0.18$). Questo accade perché il massimo puntuale del NB è instabile tra fold: per garantire che il beneficio resti positivo anche in scenari meno favorevoli, è necessario adottare una soglia meno restrittiva. Di conseguenza, la

policy robusta si attiva su una quota ampia di campagne (treat rate circa 76%), riflettendo un compromesso tra stabilità e selettività.

Al day 16 il NB medio aumenta (0.0030), coerentemente con il miglioramento predittivo osservato in RMSE. Tuttavia, il NB robusto si annulla. Questo indica che l'incremento medio non è sufficientemente stabile: il regime di plateau informativo implica che piccoli miglioramenti predittivi non si traducano necessariamente in vantaggi decisionali robusti.

Per $T = 100\%$, le soglie ottimali risultano sistematicamente più basse (ad esempio $\tau^* \approx 0.52$ al day 9). La spiegazione è strutturale: l'evento "raggiungere il 100%" è molto più raro (prevalenza circa 4%). In presenza di eventi rari, le probabilità predette tendono a concentrarsi su valori più bassi e il numero massimo di veri positivi ottenibili è limitato. Per massimizzare il NB diventa quindi necessario ridurre la soglia decisionale, accettando una maggiore tolleranza ai falsi positivi.

In altri termini, quando l'evento è raro:

- le probabilità predette sono mediamente più basse;
- il NB massimo si ottiene con soglie più contenute;
- il beneficio netto è intrinsecamente più piccolo e meno stabile.

Questo spiega perché per $T = 100\%$ le soglie siano inferiori rispetto a $T = 75\%$ e, al contempo, perché il NB robusto resti nullo: la combinazione di rarità dell'evento e incertezza residua rende difficile ottenere un vantaggio decisionale stabile rispetto alle strategie baseline.

Per $T = 100\%$, sia al day 9 sia al day 16 il NB robusto resta nullo. Anche se esiste una soglia che massimizza il NB medio, l'incertezza stimata tramite bootstrap fa sì che il lower bound includa lo zero. In altre parole, il modello non fornisce un vantaggio decisionale robusto per il raggiungimento completo del goal.

Ruolo del treat rate. Il $\text{treat rate}_{\text{rob}}$ indica la quota di campagne su cui la policy robusta si attiva. Valori elevati suggeriscono che, per ottenere anche un piccolo beneficio netto, è necessario intervenire su una frazione ampia del campione. Questo riflette il trade-off intrinseco tra sensibilità e specificità quando l'evento è poco frequente.

Nel complesso, la tabella mostra che la traduzione della previsione in decisione amplifica l'effetto della prevalenza e dell'incertezza: un miglioramento predittivo non implica automaticamente un vantaggio operativo stabile.

RMSE vs utilità decisionale. È importante notare che il miglioramento dell'accuratezza predittiva (RMSE) non si traduce automaticamente in un incremento del beneficio netto. Un modello può ridurre l'errore medio senza migliorare la separazione decisionale rilevante per una specifica soglia operativa. Questo spiega perché, nonostante l'RMSE continui a diminuire tra day 9 e day 16, il beneficio netto robusto non aumenti in modo proporzionale.

4.6 Value of Information e regola di *stop-waiting*

4.6.1 VOI: formalizzare il valore dell'attesa

Dopo la DCA, si introduce una logica sequenziale: decidere oggi oppure attendere k giorni per decidere con più informazione. Il valore dell'attesa è definito come

$$\text{VOI}(d, k) = U(d + k) - U(d) - k \cdot C_{\text{wait}},$$

dove $U(d)$ è una misura di utilità decisionale al giorno d (qui basata su NB) e C_{wait} è il costo unitario dell'attesa per giorno. In questa analisi si assume $C_{\text{wait}} = 0.002$: valori positivi di VOI indicano che conviene attendere k giorni, valori non positivi indicano che l'attesa non è giustificata dal beneficio atteso. Il valore di $C_{\text{wait}} = 0.002$ è scelto come parametro conservativo. Valori più elevati anticiperebbero il giorno di stop-waiting, mentre valori prossimi a zero renderebbero più conveniente attendere più a lungo. Un'analisi di sensibilità su tale parametro rappresenta una naturale estensione futura.

4.6.2 VOI per $T = 75\%$: utilità puntuale vs utilità robusta

La Figura 4.9 mostra il Value of Waiting per $T = 75\%$ usando come utilità il massimo NB *puntuale* (maxNB), mentre la Figura 4.10 usa l'utilità *robusta* maxNB_{low90}. In entrambi i casi si considerano orizzonti $k \in \{1, 2, 3\}$.

Il pattern è coerente con l'apprendimento front-loaded: nei primissimi giorni il VOI è più spesso positivo (attendere uno o pochi giorni può aumentare l'utilità più del costo), ma il valore dell'attesa decresce rapidamente e oscilla attorno allo zero già molto presto. La versione robusta rende il criterio più prudente: quando l'incertezza è rilevante, il guadagno "sicuro" dell'attesa è più piccolo e quindi il VOI tende a diventare non positivo più rapidamente.




Figura 4.9: Value of Waiting per $T = 75\%$ usando come utilità maxNB (puntuale), con $C_{\text{wait}} = 0.002$ e orizzonti $k \in \{1, 2, 3\}$. Valori positivi indicano convenienza ad attendere k giorni.




Figura 4.10: Value of Waiting per $T = 75\%$ usando come utilità maxNB_{low90} (robusta), con $C_{\text{wait}} = 0.002$ e orizzonti $k \in \{1, 2, 3\}$.

4.6.3 VOI per $T = 100\%$: attesa raramente conveniente in senso robusto

La Figura 4.11 riporta il Value of Waiting per $T = 100\%$ basato su utilità robusta maxNB_{low90}. Anche qui si osserva un beneficio potenziale solo nei primissimi

giorni, seguito da valori che oscillano rapidamente attorno allo zero e diventano frequentemente negativi. La combinazione tra (i) evento raro, (ii) NB vicino allo zero in DCA e (iii) costo dell'attesa spiega perché l'attesa prolungata non risulti conveniente: aumentare l'informazione non produce un incremento di utilità sufficientemente stabile da compensare il costo temporale.




Figura 4.11: Value of Waiting per $T = 100\%$ basato su utilità robusta $\max NB_{\text{low90}}$, con $C_{\text{wait}} = 0.002$ e orizzonti $k \in \{1, 2, 3\}$.

4.6.4 Regola di *stop-waiting* e implicazione operativa

Riassumendo la logica VOI, la regola di *stop-waiting* identifica il primo giorno d a partire dal quale il valore dell'attesa diventa non positivo per tutti gli orizzonti $k \in \{1, 2, 3\}$, usando una misura di utilità prudente (robusta). Con $C_{\text{wait}} = 0.002$, i risultati indicano uno *stop-day* pari a 4 per entrambi i target: oltre i primissimi giorni, l'incremento informativo atteso non compensa più il costo dell'attesa in modo robusto.

Questo risultato è particolarmente rilevante perché formalizza un punto spesso intuito ma non quantificato: il “giorno ottimale” non coincide necessariamente con quello a errore minimo (best day), bensì con quello in cui l'attesa smette di produrre un guadagno netto atteso. In pratica, una pipeline decisionale può aggiornare quotidianamente $\pi_i(T)$, applicare soglie robuste quando disponibili e interrompere l'attesa quando la stop-rule segnala che l'informazione aggiuntiva non paga più.

4.7 Lettura complessiva dei risultati

Nel complesso, i risultati convergono su tre messaggi principali.

(i) La trazione iniziale domina il contenuto informativo. L'RMSE diminuisce molto nei primi giorni (Figura 4.1) e il guadagno marginale $\Delta(d)$ decresce rapidamente (Figura 4.2), mostrando rendimenti decrescenti e un plateau informativo.

(ii) Near-optimal vs best: differenza piccola, tempo grande. Le tabelle e i grafici mostrano che day 9 è già molto vicino al best day in termini di accuratezza (Tabella 4.1 e Tabella 4.2), mentre l'attesa fino al day 20 produce guadagni medi limitati.

(iii) Utilità decisionale dipendente dal target. Per $T = 75\%$ emerge utilità decisionale precoce (Tabella 4.3 e Figura 4.5); per $T = 100\%$ il beneficio netto resta vicino allo zero (Figure 4.7 e 4.8) e il VOI robusto raramente giustifica l'attesa (Figura 4.11). La probabilità del modello è quindi particolarmente informativa come strumento di prioritizzazione/intervento per target intermedi, mentre per target estremi l'incertezza e la rarità dell'evento limitano il guadagno operativo.

Chiusura del capitolo. Nel complesso, l'analisi day-by-day con BART mostra una dinamica coerente tra accuratezza predittiva, utilità decisionale e valore dell'informazione. L'evidenza empirica indica che la maggior parte del contenuto informativo è concentrata nei primi giorni, che l'ottimo predittivo non coincide necessariamente con l'ottimo decisionale, e che il valore dell'attesa si esaurisce rapidamente in presenza di un costo temporale positivo. Questi risultati costituiscono la base per la discussione metodologica e le implicazioni economiche sviluppate nel capitolo successivo.

Capitolo 5

Discussione

Questo capitolo integra e interpreta i risultati ottenuti con i due approcci principali adottati nella tesi: (i) Random Forest (RF) in due scenari informativi (*EX-ANTE* vs *DAY-20*) e (ii) BART in impostazione *day-by-day* ($d = 1, \dots, 20$) con estensione decisionale tramite Decision Curve Analysis (DCA) e Value of Information (VOI). L'obiettivo della discussione non è ripetere tabelle e figure, ma chiarire *cosa implicano* i risultati: quali fonti informative sono davvero rilevanti, *quando* diventano disponibili e *quando* un miglioramento predittivo si traduce (o non si traduce) in un vantaggio operativo.

5.1 Quadro unitario: due esperimenti, un messaggio comune

L'evidenza empirica è coerente con un'idea semplice ma sostanziale: nel crowdfunding la dinamica precoce della raccolta (*early traction*) contiene un'informazione predittiva e decisionale che le caratteristiche statiche al lancio raramente riescono a sostituire. La Random Forest mostra un *cambio di regime* netto tra lo scenario EX-ANTE e lo scenario DAY-20: senza trazione iniziale la capacità discriminativa è prossima a quella casuale, mentre con la trazione cumulata entro 20 giorni la separazione tra classi diventa elevata e stabile. Il BART day-by-day, a sua volta, non solo conferma il ruolo centrale della trazione, ma permette di quantificare *come* il contenuto informativo cresce nel tempo: l'apprendimento è *front-loaded*, cioè gran parte della riduzione dell'errore avviene nei primi giorni, poi subentrano rendimenti marginali decrescenti (near-optimal intorno al day 9 e plateau intorno al day 16).

Infine, l'analisi decisionale (DCA e VOI) chiarisce un punto metodologico cruciale: l'ottimo predittivo (minimo RMSE al day 20) non coincide necessariamente con l'ottimo operativo. Se il tempo ha un costo, la convenienza ad attendere può esaurirsi molto prima del best day.

5.2 Random Forest: EX-ANTE vs DAY-20 come esperimento sul contenuto informativo

5.2.1 Perché EX-ANTE risulta debolmente predittivo

Nel setting EX-ANTE il modello dispone di feature strutturali (ad esempio goal e durata), testuali e emozionali disponibili al momento del lancio. L'evidenza mostra che tali segnali, pur potenzialmente correlati al successo, producono una separazione limitata: la ROC è vicina alla diagonale e l'AUC è compatibile con un classificatore quasi casuale. Dal punto di vista metodologico, questo risultato è consistente con un problema in cui le distribuzioni delle covariate condizionate sulle classi sono fortemente sovrapposte: un algoritmo flessibile come RF può modellare non linearità e interazioni, ma non può creare informazione dove non c'è [Hastie et al. \(2009\)](#); [James et al. \(2013\)](#).

In termini sostanziali, l'interpretazione è che al lancio molte campagne appaiono simili per l'osservatore esterno: il testo e la struttura possono veicolare segnali (qualità percepita, credibilità, chiarezza), ma spesso non rivelano la domanda latente né l'ampiezza della rete che effettivamente attiverà la raccolta. Questo è coerente con l'idea che il mercato “impari” osservando la risposta iniziale degli altri: meccanismi di *social proof* e dinamiche cumulative (herding) rendono informativa la trazione precoce molto più dei tratti statici [?Etter et al. \(2013\)](#).

5.2.2 DAY-20: un salto strutturale, non un miglioramento incrementale

L'aggiunta della trazione cumulata entro 20 giorni (ad esempio `pct_goal_cum_d20` e `donors_cum_d20`) determina un salto marcato su tutte le metriche (AUC, MCC, balanced accuracy e metriche probabilistiche). Metodologicamente, il punto importante è la coerenza tra:

- metriche *threshold-free* (AUC) che riflettono capacità di ranking,
- metriche *threshold-dependent* (MCC) che riflettono qualità della decisione binaria a soglia fissata,
- metriche probabilistiche (LogLoss/Brier) che riflettono qualità della probabilità stimata.

Quando tutte migliorano simultaneamente, non si tratta di un artefatto legato alla scelta della soglia: è un segnale di miglioramento reale nella struttura informativa del problema.

In termini economici, la trazione iniziale agisce come segnale aggregato della risposta del mercato e riduce rapidamente l'incertezza degli osservatori: contributi precoci possono fungere da segnali credibili che aggiornano le credenze (*signaling*) [Spence \(1973\)](#), spesso facilitati dal capitale sociale (interno o esterno) [Colombo et al. \(2015\)](#); [Zheng et al. \(2014\)](#). Questo spiega perché DAY-20 non “raffina” soltanto EX-ANTE, ma lo supera drasticamente.

5.2.3 Soglia ottimale e stabilità: plateau MCC come indicatore di robustezza

Nel caso DAY-20, la curva MCC vs soglia mostra un plateau relativamente ampio attorno alla soglia ottimale. Metodologicamente, un plateau indica che l'operatività della regola decisionale è robusta: piccole variazioni della soglia non producono grandi perdite, il che è tipico quando le distribuzioni delle probabilità predette per le due classi sono ben separate. Nel caso EX-ANTE, la curva è più fragile e il massimo MCC è basso: la soglia ottimale esiste, ma è un compromesso instabile in un regime di forte sovrapposizione.

È importante notare che la soglia è selezionata su predizioni out-of-fold (OOF). Questa scelta è metodologicamente corretta perché riduce bias ottimistici che possono emergere quando la soglia è ottimizzata sullo stesso campione usato per addestrare il modello [Cawley & Talbot \(2010\)](#). In altre parole, la comparazione tra EX-ANTE e DAY-20 non è guidata da una “soglia fortunata”, ma da una struttura predittiva realmente diversa.

5.2.4 Importanza delle variabili: traction come quasi-sufficienza empirica

Nel modello DAY-20 la variabile `pct_goal_cum_d20` domina nettamente, seguita da `donors_cum_d20`. Questo risultato è coerente con la lettura che la trazione iniziale incorpori (in forma aggregata) l'interazione tra molte determinanti: qualità percepita, network attivato, credibilità, meccanismi di diffusione. In questa prospettiva, la traction si comporta come una sorta di “statistica riassuntiva” ad alta informatività.

Al contrario, nel modello EX-ANTE l'importanza è distribuita su `goal` e segnali testuali/emozionali, ma con contributi assoluti inferiori: ciò suggerisce che tali variabili sono *correlate* all'esito ma non sono sufficientemente discriminanti. Questa evidenza è in linea con risultati recenti sul ruolo del testo: caratteristiche semantiche possono contribuire, ma spesso risultano meno determinanti rispetto alle dinamiche osservate [Lipusch et al. \(2023\)](#); [Babayoff & Shehory \(2022\)](#).

5.3 BART day-by-day

5.3.1 Perché BART: regressione, incertezza e aggiornamento sequenziale

Se la RF è impiegata come classificatore in due scenari informativi, il BART day-by-day affronta un obiettivo complementare: prevedere un esito continuo (percentuale finale di completamento) e misurare come l'accuratezza evolve quando l'informazione si accumula giorno per giorno. L'approccio day-by-day è particolarmente informativo perché evita *data leakage temporale*: ogni modello usa solo feature disponibili entro il giorno d , replicando il vincolo reale di un processo decisionale online.

Dal punto di vista metodologico, la valutazione è out-of-sample tramite cross-validation. In questo contesto è utile ricordare che la cross-validation fornisce una stima del rischio di generalizzazione, ma non un estimatore privo di varianza; inoltre, procedure ripetute di selezione (ad esempio identificare “il miglior giorno”) possono introdurre ottimismo se non trattate con cautela [Cawley & Talbot \(2010\)](#); [Nadeau & Bengio \(2003\)](#); [Bengio & Grandvalet \(2004\)](#). Nel capitolo risultati, tuttavia, il focus non è su test formali tra giorni, bensì su pattern robusti (front-loaded, near-optimal, plateau), che risultano stabili anche a fronte di piccole fluttuazioni.

5.3.2 RMSE front-loaded: interpretazione del near-optimal day e del plateau

Il profilo RMSE lungo $d = 1, \dots, 20$ mostra una riduzione marcata nei primi giorni e poi un appiattimento. Il near-optimal day (day 9) indica il primo punto in cui la performance è entro una soglia prefissata (2%) dal best day. Metodologicamente, questa scelta evita di identificare come “ottimo” un giorno solo perché minimizza marginalmente l'errore: invece, produce un criterio pragmatico basato su equivalenza approssimata. Il plateau day (day 16) formalizza l'entrata in una regione di rendimenti marginali stabilmente piccoli, coerente con il grafico del guadagno informativo marginale $\Delta(d)$.

Questa dinamica è coerente con due piani interpretativi:

- **apprendimento statistico:** una feature altamente informativa riduce rapidamente l'errore di generalizzazione, mentre informazione successiva aggiunge soprattutto dettagli ridondanti [Hastie et al. \(2009\)](#);

- **crowdfunding:** la trazione iniziale incorpora social proof, herding e capitale sociale; una volta osservata la risposta iniziale, gran parte dell'incertezza si riduce [Mollick \(2014\)](#); [Etter et al. \(2013\)](#); [Colombo et al. \(2015\)](#); [Spence \(1973\)](#).

5.3.3 Trasformazione e capping: perché sono utili ma introducono saturazione

Il target è modellato tramite trasformazione log e poi riportato sulla scala percentuale cappata a 100. Metodologicamente, trasformazioni di questo tipo sono standard per stabilizzare la varianza e ridurre asimmetrie, migliorando l'aderenza a ipotesi modellistiche e la qualità della regressione [Box & Cox \(1964\)](#); [Sakia \(1992\)](#). Il capping a 100 rende l'outcome interpretabile, ma introduce una conseguenza strutturale: molte campagne “molto performanti” vengono schiacciate allo stesso valore, rendendo più difficile distinguere la coda alta. Questo aiuta a capire perché, anche quando l'RMSE migliora, restano difficoltà specifiche nella predizione di esiti estremi.

5.3.4 Diagnostiche: compressione e forma degli errori

I grafici predetto-vs-vero mostrano compressione delle previsioni verso valori intermedi e accumulo ai limiti (0 e 100). Dal punto di vista metodologico, la compressione è tipica di modelli regolarizzati/ensemble: ridurre la varianza predittiva migliora la generalizzazione, ma “smussa” gli estremi. L'accumulo vicino a 100 è invece una conseguenza diretta del capping: riduce la varianza osservabile nella coda alta e rende più difficile la separazione tra campagne altamente performanti, tema che riemerge anche nella parte decisionale per $T = 100\%$.

5.4 RF vs BART: complementarità, non ridondanza

A questo punto è utile chiarire perché i due approcci non sono alternative equivalenti ma strumenti complementari.

(i) **Target e domanda diversa.** La RF risponde a una domanda di classificazione binaria (successo/non successo) in due scenari informativi e quantifica il salto dovuto alla trazione. Il BART risponde a una domanda di regressione (quanto completerà la campagna) e misura la dinamica temporale della qualità predittiva, evidenziando near-optimal e plateau.

(ii) **Orizzonte temporale.** La RF confronta due istanti (lancio vs 20 giorni), mostrando un “prima e dopo”. Il BART mostra l’intero percorso, rendendo evidente che gran parte dell’informazione arriva presto e che i miglioramenti successivi sono marginali.

(iii) **Dal predittivo al decisionale.** L’estensione DCA/VOI su BART consente di passare da accuratezza media (RMSE) a valore operativo (Net Benefit e valore dell’attesa). Questo passaggio è metodologicamente cruciale: un modello può ridurre l’errore senza aumentare il beneficio netto per una policy basata su soglia, perché RMSE e utilità decisionale misurano proprietà diverse della previsione (errore medio vs separazione utile attorno a soglie operative).

5.5 DCA: quando la previsione diventa utile per decidere

5.5.1 Perché DCA: evitare soglie arbitrarie e incorporare costi/benefici

La Decision Curve Analysis valuta una policy “intervieni se $\pi_i(T) \geq \tau$ ” confrontandola con *treat-all* e *treat-none*. Metodologicamente, è un approccio che evita scelte arbitrarie di soglia: lascia che sia il trade-off implicito tra falsi positivi e falsi negativi (incorporato da τ) a determinare dove il modello è utile. La banda al 90% via Bayesian bootstrap aggiunge una lettura prudente: non basta che NB sia positivo in media, occorre che sia *robustamente* positivo.

5.5.2 Perché per $T = 75\%$ emerge utilità precoce

Per $T = 75\%$ il modello diventa decisionalmente utile già al giorno 2 ($d_{dec} = 2$). L’interpretazione è che l’evento “raggiungere almeno il 75%” ha prevalenza più alta e un confine meno estremo; quindi il modello può generare probabilità sufficientemente informative già molto presto, permettendo una policy che batte le baseline in modo robusto.

5.5.3 Perché per $T = 100\%$ compare NA

Il valore NA per $T = 100\%$ non indica che il modello “non predice”, ma che *non esiste alcun giorno* in cui, per almeno una soglia τ , il lower bound al 90% del NB (in media sui fold) sia positivo. In altre parole: quando si richiede robustezza, il vantaggio decisionale non è distinguibile da zero.

Questo risultato è coerente con tre fattori:

- **Evento raro:** la prevalenza è circa 4%, e con eventi rari è più difficile ottenere guadagni netti stabili; piccole variazioni di ranking possono cambiare molto la matrice di confusione.
- **Saturazione del target:** l'evento $T = 100\%$ è vicino al bordo superiore, dove il capping schiaccia molte osservazioni e rende più difficile discriminare in modo fine.
- **Incertezza residua:** anche se l'accuratezza puntuale migliora con d , la separazione decisionale “utile” può rimanere instabile; ciò spiega perché RMSE e NB non necessariamente si muovono insieme.

5.5.4 RMSE vs Net Benefit: perché possono divergere

È essenziale distinguere la funzione obiettivo:

- RMSE penalizza l'errore quadratico medio sulla variabile continua;
- NB valuta una policy binaria legata a soglia e costi relativi di errori.

Un miglioramento di RMSE può derivare da correzioni in regioni del dominio poco rilevanti per la policy, oppure da riduzioni di errori piccoli e frequenti che non cambiano la classificazione attorno alla soglia decisionale. Per questo motivo è possibile osservare rendimenti marginali decrescenti in RMSE e contemporaneamente un appiattimento (o annullamento) del NB robusto.

5.6 VOI e stop–waiting: il timing ottimale non è il best day

5.6.1 VOI come criterio sequenziale coerente con un costo del tempo

Il VOI formalizza un trade-off realistico: attendere aumenta informazione, ma riduce tempestività. Definendo $\text{VOI}(d, k) = U(d + k) - U(d) - k C_{\text{wait}}$, la convenienza ad attendere dipende dall'incremento di utilità e dal costo del rinvio. Con $C_{\text{wait}} = 0.002$, lo *stop–day* risulta 4 per entrambi i target (versione robusta), indicando che oltre i primissimi giorni l'informazione addizionale non compensa in modo prudente il costo dell'attesa.

Questo non contraddice il near-optimal day (9). Al contrario, chiarisce che:

- day 9 è un ottimo *predittivo-pragmatico* (accuratezza quasi massima);

- day 4 è un ottimo *decisionale* dato un costo del tempo positivo e una scelta robusta dell'utilità.

In applicazioni reali, questa distinzione è centrale: ciò che “conviene” dipende dall'obiettivo (stima accurata vs intervento tempestivo) e dal costo-opportunità del tempo.

5.6.2 Sensibilità a C_{wait} : cosa aspettarsi

Il parametro C_{wait} governa direttamente lo stop-day: valori più alti anticipano l'arresto, valori più bassi rendono più conveniente attendere. Per questo, una naturale estensione è un'analisi di sensibilità (ad esempio $C_{\text{wait}} \in [0, 0.01]$) per produrre una mappa “costo $\rightarrow$ timing ottimale”, utile anche per comunicare il risultato a stakeholder non tecnici.

5.7 Limite metodologico: coverage bassa e calibrazione dell'incertezza

Un risultato robusto ma critico è la bassa coverage degli intervalli al 95% sulla scala percentuale cappata (circa 0.30–0.38). Metodologicamente, ciò suggerisce intervalli troppo stretti e incertezza sottostimata. Una spiegazione coerente è che gli intervalli siano costruiti principalmente dai draw della funzione latente $f(x)$ piuttosto che dalla distribuzione predittiva completa $y = f(x) + \varepsilon$; inoltre, trasformazioni non lineari e capping comprimono le code e possono peggiorare la copertura sulla scala finale [Box & Cox \(1964\)](#); [Sakia \(1992\)](#).

Implica due cose:

- le conclusioni su *timing* e *valore relativo dell'informazione* restano informative (perché si basano su confronti e pattern temporali);
- la lettura “assoluta” di intervalli e probabilità richiede cautela; per migliorare, è naturale generare draw posterior-predittivi includendo rumore e rivalutare coverage e DCA.

5.8 Implicazioni pratiche ed estensioni

I risultati suggeriscono una strategia operativa in due livelli.

1. **Predizione precoce (stima continua):** se l'obiettivo è stimare bene la percentuale finale, il day 9 è un compromesso molto efficiente tra accuratezza e tempestività; il plateau day (16) segnala che attendere oltre produce miglioramenti marginali ridotti.
2. **Decisione precoce (policy):** se l'obiettivo è decidere interventi (promozione, supporto, reallocazione risorse), allora DCA/VOI indicano che il valore dell'attesa si esaurisce molto presto (stop-day ≈ 4 nella versione robusta), soprattutto per target intermedi ($T = 75\%$) dove esiste utilità decisionale precoce.

Tra le estensioni più rilevanti:

- **Sensibilità VOI:** variare C_{wait} e l'insieme degli orizzonti k per ottenere una frontiera costo-tempo.
- **Metriche per eventi rari:** per target estremi e class imbalance, integrare PR-curve e misure evento-specifiche [Davis & Goadrich \(2006\)](#).
- **Validazione temporale:** se disponibile un ordinamento temporale delle campagne, usare split temporali per stressare la generalizzazione (riducendo rischi di leakage e ottimismo) [Kaufman et al. \(2012\)](#); [Cawley & Talbot \(2010\)](#).
- **Sottogruppi e contesto:** analisi per categorie o tipologie (ad esempio disaster/non-disaster), per capire se il timing informativo cambia con il contesto.

Implicazione temporale

Supporre a priori la durata totale di una raccolta fondi è stata una assunzione forte ma che è possibile motivare attraverso il senso della beneficenza. Una raccolta nasce già implicando che l'organizzatore sia disposto a donare il proprio tempo affinché la causa raggiunga il successo: quanto un donatore è più disposto a donare tempo quanto più consecutivamente si alzerà la probabilità di riuscita della campagna. Questo aspetto rende più coerente la stima e i modelli con l'idea probabilistica che si cela dietro al metodo applicato.

Chiusura. Nel complesso, i risultati di RF e BART convergono su un messaggio robusto: la trazione iniziale non è una feature additiva ma l'elemento che determina il passaggio da un regime informativamente debole (EX-ANTE) a un regime predittivamente e operativamente sfruttabile. Il BART day-by-day quantifica *quando*

la qualità predittiva diventa quasi ottimale (near-optimal day) e, tramite DCA/VOI, mostra che il timing ottimale per decidere può essere ancora più precoce quando il tempo ha un costo. Questa distinzione tra ottimo predittivo e ottimo decisionale è la principale implicazione metodologica della tesi e costituisce la base per le conclusioni finali.

Capitolo 6

Applicazione del framework a *Adotta un Sogno*

6.1 Obiettivo del capitolo

I risultati sviluppati nei capitoli precedenti mostrano che, nelle campagne donation-based, la componente informativa decisiva emerge molto presto: la trazione iniziale genera un cambio di regime rispetto alle sole informazioni disponibili al lancio, e il valore dell’attesa tende a esaurirsi rapidamente quando il tempo ha un costo. [Breiman \(2001\)](#) [Kaufman et al. \(2012\)](#) Questo capitolo traduce tali evidenze in un piano operativo per sostenere un’iniziativa reale: il progetto *Adotta un Sogno* di Coccole di Nir, finalizzato a finanziare un anno di studi per un ragazzo dell’orfanotrofio di Saranya al confine tra Thailandia e Myanmar.

6.2 Il contesto: perché “Adotta un Sogno” è un caso rilevante

Il progetto nasce dall’esigenza concreta di garantire la prosecuzione degli studi oltre la scuola dell’obbligo (che nel villaggio si ferma ai 14 anni). Per frequentare la scuola superiore, i ragazzi devono trasferirsi (la destinazione più vicina è Chiang Mai, circa sei ore di distanza), sostenendo costi che includono retta scolastica, vitto e alloggio, libri e materiale, trasporti e spese essenziali. Il costo medio stimato per studente è pari a circa **€3.900 per un anno**, articolabile in voci tipiche (scuola, materiale scolastico, vitto/alloggio, trasporti).

6.3 Dal modello al processo: una strategia informativa in due stadi

La tesi ha distinto due set informativi: **EX-ANTE** (segnali disponibili al lancio) e **DAY-20** (EX-ANTE + trazione cumulata entro 20 giorni), evidenziando che l'early traction domina il contenuto informativo e rende il problema predittivamente e operativamente sfruttabile. Mollick (2014) Etter et al. (2013) Per *Adotta un Sogno* proponiamo quindi una gestione *sequenziale* della campagna, articolata in due momenti coerenti con il vincolo anti-leakage e con la logica di aggiornamento dell'informazione:

6.3.1 Stadio 1 — Lancio (EX-ANTE): progettare per massimizzare la trazione iniziale

Lo scenario EX-ANTE, da solo, è informativamente debole: al lancio molte campagne appaiono simili e la narrazione non basta a rivelare la “domanda latente” (ampiezza rete, capacità di attivazione, social proof). Ne segue un'implicazione pratica: la fase di lancio va progettata non per “predire”, ma per **innescare trazione**. Operativamente, ciò significa:

- **Chiarezza del bisogno in formato scomponibile:** presentare il goal annuale (≈ 3.900) come somma di voci comprensibili (retta, vitto/alloggio, materiale, trasporti), riducendo ambiguità e aumentando credibilità percepita.
- **Aiuti compatibili con budget diversi:** enfatizzare che si può contribuire con quota mensile o una tantum, rendendo accessibile l'ingresso anche a piccoli donatori.
- **Piano di attivazione della rete nei primissimi giorni:** concentrare comunicazione, condivisioni e contatti diretti nella finestra iniziale, perché è lì che si genera il segnale osservabile dagli altri donatori.

6.3.2 Stadio 2 — Monitoraggio precoce: aggiornare con trazione e decidere

I risultati day-by-day mostrano un apprendimento *front-loaded*: gran parte dell'informazione utile emerge presto (near-optimal attorno a day 9) e i rendimenti marginali decrescono (plateau più avanti). Inoltre, strumenti decisionali (DCA/VOI)

suggeriscono che, se il tempo ha un costo, può essere razionale non attendere il “giorno migliore” in termini di RMSE, ma attivare decisioni prima (stop–waiting molto precoce in versione prudente). Cawley & Talbot (2010) Efron & Tibshirani (1993) Per *Adotta un Sogno* proponiamo quindi un **cruscotto di monitoraggio** e una **regola di azione**:

Indicatori minimi (aggiornati quotidianamente).

- `pct_goal_cum_d`: percentuale del goal raggiunta entro il giorno d ;
- `donors_cum_d`: numero cumulato di donatori entro il giorno d ;
- Δ giornaliera della trazione (proxy di “velocità”).

Una policy semplice e trasparente. Dato un giorno d , si produce una probabilità di raggiungere un obiettivo operativo T (ad esempio $T = 75\%$ del goal annuale) e si applica una regola del tipo:

$$\text{Intervieni se } \pi(d, T) \geq \tau,$$

dove l’“intervento” non è una decisione sul donare, ma un’azione di gestione della campagna: spinta social, contatti mirati, aggiornamenti pubblici, o supporto di comunicazione.

6.4 Interventi concreti: cosa fare quando i segnali lo suggeriscono

Coerentemente con la logica della Decision Curve Analysis, l’idea è **allocare risorse dove il beneficio atteso supera le baseline** (intervenire su tutti / non intervenire su nessuno). In pratica, definiamo tre livelli di intensità:

6.4.1 “Rilancio leggero”

Da attivare quando la trazione è presente ma ancora fragile (segnali incerti):

- aggiornamento pubblico con progresso numerico (% e €) e micro-obiettivo successivo;
- testimonianza/contesto (perché la scuola superiore abilita futuro e diritti);
- reminder con opzione di quota mensile.

6.4.2 “Spinta mirata”

Da attivare quando il modello/score indica buona probabilità di raggiungere un target intermedio:

- contatto diretto (mail/WhatsApp) a cerchie ad alta propensione (ex donatori, reti locali);
- contenuti brevi ripetuti (storie, post) focalizzati su 1 voce di costo per volta;

6.4.3 “Accelerazione”

Da attivare solo quando la trazione è robusta (segnale forte) e l’aumento di risorse ha alta probabilità di trasformarsi in successo:

- collaborazione con pagine/creator/associazioni;
- evento di raccolta o diretta con aggiornamenti in tempo reale;
- comunicazione “one-year funded” come traguardo unitario e verificabile.

Alla luce dei risultati empirici emersi nei modelli precedenti, risulta strategicamente opportuno concentrare il massimo sforzo promozionale nei primissimi giorni di campagna. L’evidenza mostra infatti che la trazione iniziale agisce come variabile quasi-sufficiente del successo finale: ciò implica che ogni intervento volto ad aumentare rapidamente il numero di donatori e la quota di obiettivo raggiunta ha un effetto moltiplicativo sulla probabilità complessiva di successo. In questa fase, l’obiettivo prioritario non è soltanto raccogliere capitale finanziario, ma ampliare il più possibile la rete attiva di sostenitori, rafforzando il capitale sociale del progetto. L’estensione della base di donatori nelle fasi iniziali aumenta la visibilità, genera segnali pubblici di credibilità e attiva meccanismi di imitazione e coordinamento. Pertanto, l’applicazione tempestiva e intensiva di interventi promozionali nei primi giorni non rappresenta un semplice supporto operativo, ma una scelta coerente con la struttura informativa del fenomeno osservato.

6.5 Perché puntare a target intermedi (e non solo al 100%)

Un punto chiave emerso è che target estremi (raggiungere il 100%) possono essere più difficili da supportare con vantaggio decisionale robusto, anche quando l’accuratezza media migliora: eventi più rari e saturazioni rendono instabile il guadagno netto.

Per questo, in una campagna come *Adotta un Sogno* è utile lavorare per **obiettivi intermedi** (ad esempio 25%, 50%, 75%) che:

- aumentano frequenza di “successi parziali” comunicabili;
- generano social proof ripetuto;
- riducono l’attrito psicologico del traguardo unico.

6.6 Una proposta operativa di calendario: primi giorni come finestra critica

Alla luce della dinamica front-loaded, proponiamo una scansione essenziale:

- **Giorni 0–2:** massima concentrazione di attivazione (rete calda, annunci, primo aggiornamento).
- **Giorni 3–4:** prima decisione operativa (*stop-waiting* in senso prudente): scegliere se passare a Pacchetto B/C oppure ricalibrare narrazione e canali.
- **Giorni 5–9:** ottimizzazione “quasi ottimale” (near-optimal): consolidare la trazione con obiettivi e contenuti ripetibili.
- **Oltre:** interventi selettivi; evitare escalation continua se i rendimenti marginali si riducono (logica di plateau).

6.7 Trasparenza e misurabilità: come rendere credibile il goal

Per rafforzare fiducia e conversione, il goal annuale va reso verificabile e monitorabile:

- dettaglio delle voci (scuola, materiale, vitto/alloggio, trasporti);
- aggiornamenti periodici con % raggiunta e prossima soglia;
- rendicontazione a posteriori (anche sintetica) sull’uso delle risorse.

Questo si allinea con il ruolo della trazione come “segnale aggregato” e con la necessità di rendere il segnale credibile.

6.8 Limiti e cautele nell'uso decisionale

Il framework fornisce una guida quantitativa, ma va usato con cautele:

- la probabilità predetta è uno *score* per prioritizzare interventi, non un verdetto deterministico;
- l'incertezza può essere sottostimata se gli intervalli non sono perfettamente calibrati; è quindi preferibile una lettura prudente e orientata al confronto tra alternative.

6.9 Chiusura

In sintesi, l'applicazione a *Adotta un Sogno* mostra come i risultati della tesi possano trasformarsi in una **pipeline operativa**: progettare il lancio per massimizzare la trazione, monitorare precocemente segnali cumulati, e decidere interventi con una logica sequenziale che riconosce il costo del tempo. L'obiettivo pratico è rendere più probabile il finanziamento di **un anno di studi (circa €3.900) per un bambino**, attraverso scelte tempestive e misurabili, coerenti con la dinamica informativa osservata empiricamente nelle campagne donation-based.

6.10 Perché questa ricerca può effettivamente essere d'aiuto

Fare del bene, quando se ne ha la possibilità, è spesso più semplice di quanto immaginiamo. Ciò che talvolta rende difficile l'azione non è la mancanza di volontà, ma l'incertezza: non sapere da dove iniziare, quando intervenire, come interpretare i segnali lungo il percorso. Questa ricerca contribuisce proprio a ridurre tale incertezza, offrendo non soltanto strumenti predittivi, ma vere e proprie *mappe temporali* che aiutano a orientarsi nel ciclo di vita di una campagna.

Avere una scansione chiara delle fasi — lancio, primi segnali di trazione, eventuale plateau — consente di trasformare un'intenzione generica in una strategia consapevole. Gli obiettivi sequenziali rendono visibile il progresso, permettono di valutare con maggiore lucidità la probabilità di successo e aiutano a decidere quando rafforzare l'impegno o ricalibrare l'azione. In questo senso, la dimensione temporale non è soltanto una variabile tecnica, ma uno strumento etico: rende l'azione più responsabile perché più informata.

È inoltre più facile perseverare quando ci si impone traguardi intermedi. Suddividere un obiettivo complessivo in soglie progressive — 25%, 50%, 75% — riduce la

distanza percepita dal risultato finale e rafforza la motivazione collettiva. L'astrazione di un grande obiettivo si traduce così in passi concreti, misurabili, raggiungibili.

Se, come ha mostrato Hannah Arendt riflettendo sulla “banalità del male”, il compimento del male può assumere forme ordinarie e quotidiane, allora è plausibile ritenere che anche il bene possa seguire una logica altrettanto accessibile. Anzi, con strumenti adeguati e linee guida chiare, fare il contrario — agire responsabilmente per generare impatto positivo — può risultare ancora più semplice. La differenza sta nella consapevolezza e nella struttura dell'azione.

Infine, questa ricerca offre un valore concreto anche a chi, come l'autore, non aveva precedenti esperienze di raccolta fondi. Disporre di evidenze empiriche, indicatori interpretabili e criteri decisionali riduce la distanza tra teoria e pratica. Permette un primo approccio più sicuro, meno intuitivo e più fondato su dati osservabili. In altre parole, trasforma un atto di generosità in un processo guidato, aumentando la probabilità che l'intenzione iniziale si traduca in un risultato effettivo.

In questo senso, il contributo della ricerca non è soltanto metodologico, ma anche culturale: dimostra che l'efficacia del bene può essere progettata, monitorata e migliorata, rendendo l'azione solidale non solo desiderabile, ma anche strategicamente sostenibile.

Capitolo 7

Conclusioni

Questa tesi ha studiato la previsione dell'esito di campagne di crowdfunding e, soprattutto, il *timing* con cui l'informazione diventa utile per supportare decisioni operative. L'analisi ha combinato due blocchi metodologici complementari: (i) un esperimento Random Forest (RF) in due scenari informativi (*EX-ANTE* vs *DAY-20*) per quantificare il guadagno informativo della trazione iniziale; (ii) un approccio BART *day-by-day* ($d = 1, \dots, 20$) per ricostruire la dinamica temporale dell'accuratezza e collegarla a strumenti decisionali (Decision Curve Analysis e Value of Information).

7.1 Risultati principali

I risultati convergono su tre conclusioni principali, coerenti tra i due esperimenti.

7.1.1 La trazione iniziale domina il contenuto informativo

Il confronto RF tra EX-ANTE e DAY-20 mostra un cambio di regime netto: le sole informazioni disponibili al lancio (feature strutturali, testuali ed emozionali) producono una capacità discriminativa limitata e prossima a quella casuale, mentre l'inclusione della trazione cumulata entro 20 giorni genera un forte miglioramento simultaneo di AUC, MCC e metriche probabilistiche. Questo non rappresenta un semplice raffinamento, ma indica che l'*early traction* incorpora una quota decisiva di informazione sulla domanda latente e sui meccanismi di diffusione.

Questa evidenza è coerente con la letteratura sul crowdfunding: dinamiche cumulative e *social proof* rendono i contributi precoci altamente informativi [Mollick \(2014\)](#); [Etter et al. \(2013\)](#), mentre il capitale sociale e le reti possono amplificare la capacità di attrazione iniziale [Colombo et al. \(2015\)](#); [Zheng et al. \(2014\)](#). In ottica

di signaling, la trazione agisce come segnale osservabile che aggiorna rapidamente le credenze sulla qualità e sulla probabilità di successo [Spence \(1973\)](#).

7.1.2 L'apprendimento è front-loaded: quasi tutto “si vede” presto

L'analisi BART day-by-day consente di passare da una fotografia (lancio vs day-20) a un film dell'informazione. L'andamento dell'errore out-of-sample mostra una riduzione marcata nei primi giorni e poi rendimenti marginali decrescenti: il *near-optimal day* cade intorno al giorno 9 (performance entro una soglia prefissata dal best day), mentre un *plateau* informativo emerge intorno al giorno 16. Questa dinamica quantifica un fatto operativo: attendere oltre la prima metà dell'orizzonte osservato produce miglioramenti medi piccoli rispetto ai guadagni iniziali.

Dal punto di vista metodologico, la scelta di un criterio near-optimal (invece di inseguire il minimo RMSE) è importante perché evita di attribuire significato eccessivo a differenze marginali che possono essere compatibili con fluttuazioni campionarie e varianza della cross-validation [Cawley & Talbot \(2010\)](#); [Nadeau & Bengio \(2003\)](#); [Bengio & Grandvalet \(2004\)](#). In altri termini, il risultato chiave non è “il giorno migliore in assoluto”, ma la struttura robusta: informazione precoce e rendimenti decrescenti.

7.1.3 Ottimo predittivo e ottimo decisionale non coincidono

L'estensione decisionale con DCA e VOI chiarisce la conclusione più rilevante per un'implementazione reale: un miglioramento predittivo (riduzione RMSE) non implica automaticamente un incremento dell'utilità operativa. La DCA mostra che l'utilità positiva (Net Benefit) si concentra su soglie τ basse e dipende fortemente dal target decisionale. Per $T = 75\%$ emerge utilità *robusta* molto presto ($d_{dec} = 2$), mentre per $T = 100\%$ non emerge alcun giorno con beneficio netto robustamente positivo (**NA**), coerentemente con rarità dell'evento e difficoltà di discriminare esiti estremi in presenza di saturazione del cap a 100.

Il VOI formalizza poi il trade-off informazione–tempestività: quando il tempo ha un costo ($C_{wait} > 0$), il valore atteso dell'attesa si esaurisce rapidamente. La regola di *stop–waiting* indica uno stop intorno ai primissimi giorni (circa day 3–4 nella versione robusta), mostrando che il timing “razionale” per decidere può essere molto più precoce del best day. Questa distinzione tra *ottimo predittivo* (minimo RMSE) e *ottimo decisionale* (massimo valore netto atteso dato il costo del tempo) è la principale implicazione metodologica della tesi.

7.2 Contributi metodologici e implicazioni operative

Alla luce dei risultati, i contributi principali possono essere sintetizzati in tre punti.

7.2.1 Un esperimento causale-informativo sul ruolo della trazione

Il confronto EX-ANTE vs DAY-20 in RF funziona come esperimento sul contenuto informativo: mostra che, senza osservare la risposta iniziale del mercato, il problema è debolmente predittivo; con la trazione, diventa strutturalmente separabile. In termini applicativi, ciò suggerisce che pipeline basate solo su testo e caratteristiche statiche possono essere utili per screening iniziale, ma non sostituiscono un aggiornamento precoce basato su segnali dinamici.

7.2.2 Una mappa temporale dell'informazione

Il BART day-by-day fornisce una mappa del valore informativo nel tempo: identifica un punto efficiente di previsione (day 9) e un plateau (day 16). Operativamente, ciò suggerisce un uso “a due velocità”: predizioni affidabili già nella prima metà della campagna, con guadagni marginali limitati nel proseguimento.

7.2.3 Un ponte esplicito tra previsione e decisione

DCA e VOI trasformano la previsione in decisione: non si valuta soltanto *quanto* si predice bene, ma *quanto* una regola di intervento migliora rispetto a baseline semplici e *quando* conviene agire. In un contesto manageriale, questo consente di progettare una policy scalabile: aggiornare quotidianamente le probabilità, applicare soglie coerenti con costi/benefici e interrompere l'attesa quando il guadagno marginale non compensa più il costo del tempo.

7.3 Limiti e raccomandazioni per lavori futuri

I risultati sono robusti nei pattern principali, ma alcuni limiti rimangono rilevanti.

7.3.1 Calibrazione e coverage degli intervalli

La coverage degli intervalli nominali al 95% sulla scala percentuale cappata risulta molto inferiore al nominale. Questo suggerisce incertezza sottostimata e invita a cautela nell'interpretazione “assoluta” degli intervalli. Una direzione naturale è generare veri *posterior predictive draws* includendo esplicitamente la componente di

rumore e rivalutare coverage e DCA con intervalli calibrati; inoltre, trasformazioni non lineari e capping possono comprimere le code e complicare la calibrazione [Box & Cox \(1964\)](#); [Sakia \(1992\)](#).

7.3.2 Eventi rari e metriche più informative

Per target estremi ($T = 100\%$) e class imbalance, è opportuno affiancare metriche e curve più sensibili all'evento raro (ad esempio PR-curve), spesso più informative della ROC in questi setting [Davis & Goadrich \(2006\)](#).

7.3.3 Validazione temporale e robustezza

Se disponibili timestamp affidabili, uno split temporale consentirebbe di stressare la generalizzazione nel tempo e ridurre rischi di leakage [Kaufman et al. \(2012\)](#). Inoltre, un'analisi di sensibilità rispetto a C_{wait} e agli orizzonti k produrrebbe una frontiera costo-timing utile per l'adozione pratica.

7.4 Conclusione finale

In sintesi, la tesi mostra che nel crowdfunding l'informazione davvero decisiva emerge presto: la trazione iniziale non è una variabile aggiuntiva, ma il fattore che trasforma un problema debolmente predittivo in un problema operativamente sfruttabile. Il contributo principale è aver distinto e collegato tre livelli: (i) *contenuto informativo* (EX-ANTE vs DAY-20), (ii) *dinamica temporale* dell'accuratezza (near-optimal e plateau), (iii) *valore decisionale* dell'attesa (DCA/VOI). Ne deriva una conclusione pratica chiara: se l'obiettivo è intervenire in modo tempestivo, attendere fino al “giorno migliore” in termini di RMSE non è in generale ottimale; la decisione può (e spesso deve) essere anticipata, soprattutto per target intermedi in cui emerge utilità robusta già nei primi giorni.

Bibliografia

- BABAYOFF, O. & SHEHORY, O. (2022). The role of semantics in the success of crowdfunding projects. *PLOS ONE* **17**, e0263891.
- BENGIO, Y. & GRANDVALET, Y. (2004). No unbiased estimator of the variance of k-fold cross-validation. *Journal of Machine Learning Research* **5**, 1089–1105.
- BOX, G. & COX, D. (1964). An analysis of transformation , 211–243.
- BREIMAN, L. (2001). Random forests. *Machine Learning* **45**, 5–32.
- CAWLEY, G. C. & TALBOT, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research* **11**, 2079–2107.
- CHICCO, D. & JURMAN, G. (2020). The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation. *BMC Genomics* **21**, 6.
- COLOMBO, M. G., FRANZONI, C. & ROSSI-LAMASTRA, C. (2015). Internal social capital and the attraction of early contributions in crowdfunding. *Entrepreneurship theory and practice* **39**, 75–100.
- DAVIS, J. & GOADRICH, M. (2006). The relationship between precision-recall and roc curves. *Proceedings of the 23rd International Conference on Machine Learning (ICML)* , 233–240.
- DELONG, E. R., DELONG, D. M. & CLARKE-PEARSON, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics* **44**, 837–845.
- EFRON, B. & TIBSHIRANI, R. J. (1993). *An Introduction to the Bootstrap*. Chapman and Hall/CRC.

- ETTER, V., GROSSGLAUSER, M. & THIRAN, P. (2013). Launch hard or go home!: Predicting the success of kickstarter campaigns. In *Proceedings of the 2013 Conference on Online Social Networks (COSN '13)*. ACM.
- HASTIE, T., TIBSHIRANI, R. & FRIEDMAN, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2nd ed.
- HE, H. & GARCIA, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering* **21**, 1263–1284.
- JAMES, G., WITTEN, D., HASTIE, T. & TIBSHIRANI, R. (2013). *An Introduction to Statistical Learning with Applications in R*. Springer.
- KAUFMAN, S., ROSSET, S. & PERLICH, C. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data* **6**, 1–21.
- KOHAVI, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*.
- KUHN, M. & JOHNSON, K. (2013). *Applied Predictive Modeling*. Springer.
- KUPPUSWAMY, V. & BAYUS, B. L. (2017). Crowdfunding creative ideas: The dynamics of project backers. *Innovation Policy and the Economy* **17**, 151–182.
- LIPUSCH, N., MELCHERS, R. & HILLE, S. (2023). Explainable text-based features in predictive models of crowdfunding success. *Annals of Operations Research* .
- MOLLICK, E. (2014). The dynamics of crowdfunding: An exploratory study. *Journal of business venturing* **29**, 1–16.
- NADEAU, C. & BENGIO, Y. (2003). Inference for the generalization error. *Machine Learning* **52**, 239–281.
- NAHAPIET, J. & GHOSHAL, S. (1998). Social capital, intellectual capital, and the organizational advantage. *Academy of management review* **23**, 242–266.
- SAITO, T. & REHMSMEIER, M. (2015). The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE* **10**, e0118432.

- SAKIA, R. M. (1992). The box-cox transformation technique: A review , 169–178.
- SPENCE, M. (1973). Job market signaling. *The quarterly journal of Economics* **87**, 355–374.
- TUKEY, J. W. (1957). On the comparative anatomy of transformation diagnostics , 602–632.
- VARMA, S. & SIMON, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics* **7**, 91.
- ZHENG, H., LI, D., WU, J. & XU, Y. (2014). The role of multidimensional social capital in crowdfunding: A comparative study in china and us. *Information & Management* **51**, 488–496.